

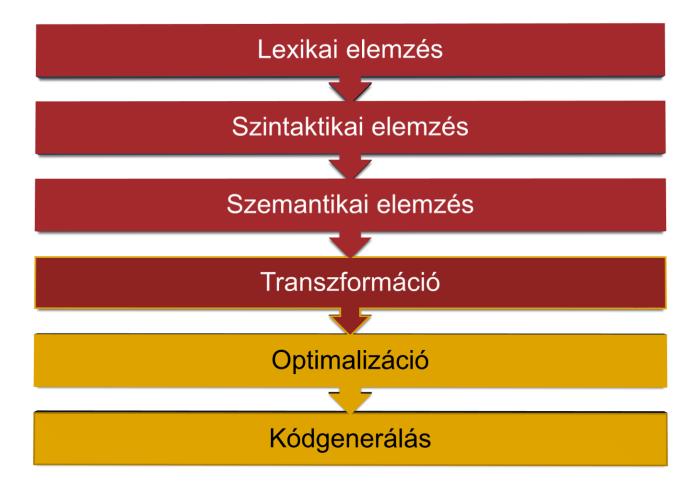
Modellalapú szoftverfejlesztés

VI. előadás

Optimalizáció, Obfuszkáció, Kódgenerálás

Dr. Mezei Gergely, Dr. Somogyi Ferenc

Fordítás fázisai



Optimalizálás, obfuszkálás, kódgenerálás

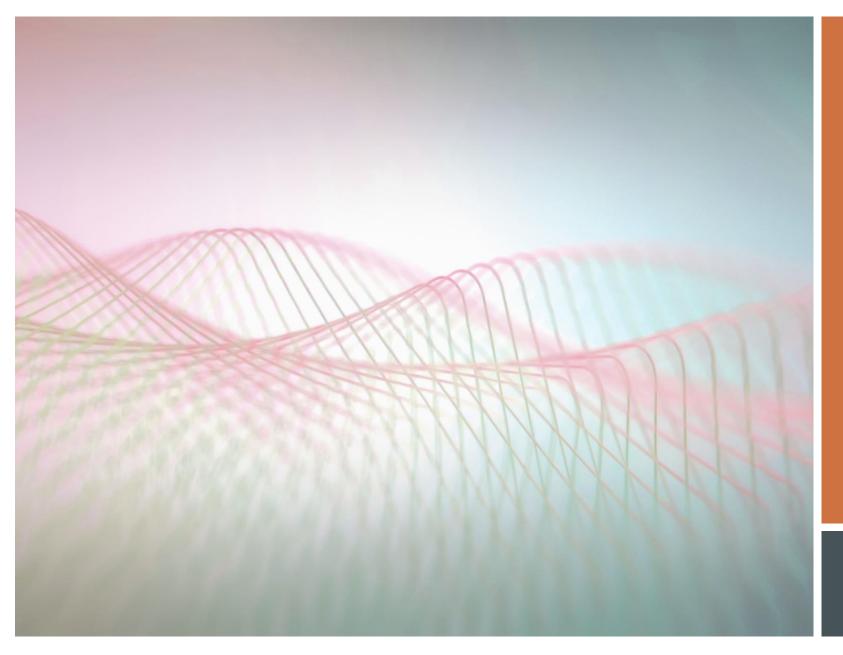
I. Optimalizáció (folytatás)

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás





Adatfolyam optimalizáció

Adatfolyam optimalizáció

- Közös kifejezés (common subexpression)
- Konstans/változó propagáció (constant/copy propagation)
- Elérhető kifejezések
- Halott kód (dead code)
- Élő változók felderítése

Csak alapblokkon belül (lokális)!

Common subexpression

- Ne számoljuk ki kétszer ugyanazt!
 - Ha az operandusok nem változtak és a művelet mellékhatás mentes

```
... a = b \odot c + 5

e = (b \odot c) * 2

...
```



```
...

tmp = b 0 c

a = tmp + 5

e = tmp * 2

...
```

Constant propagation

 Ha egy változóba konstans érték kerül, akkor a változót lecserélhetjük az értékre

```
...
  a = 7
  b = a ⊙ 3
  ...
  if (a > 4) { write("."); }
...
```



```
...
    a = 7
    b = 7 ⊙ 3
    ...
    write(".");
...
```

Copy propagation

Ha két változó értéke megegyezik, kicserélhetőek

```
... a = b \odot c d = a e = d * 5 + 8 ...
```



```
... a = b \odot c d = a e = a * 5 + 8 ...
```

Optimalizáció - példa

```
b = a * a;
c = a * a;
d = b + c;
e = 1;
f = b + b;
g = f * e;
...
```

Elérhető kifejezések

- Elérhető kifejezés (available expression): ha van aktuálisan olyan változó, ami a kifejezés értékét tartalmazza, akkor a kifejezés lecserélhető a változóra
- Elérhető kifejezések felderítése
 - > Kezdetben üres halmaz
 - > a = b ⊙ c kifejezésnél
 - Az a-t tartalmazó kifejezéseket kivesszük
 - a= b ⊙ c kifejezést betesszük

Elérhető kifejezések alkalmazása

```
a = b;
\{a=b\}
c = a;
{a = b, c = b}
d = a + b;
\{a = b, c = b, d = a + b\}
e = d;
\{a = b, c = b, d = a + b, e = a + b\}
d = a;
\{ a = b, c = b, d = b, e = a + b \}
f = e;
\{a = b, c = b, d = b, e = a + b, f = a + b\}
```

Dead code

 Ha egy értékadás bal oldalán szereplő változó értékét sehol nem olvassuk ki, akkor az értékadás törölhető

```
... a = b \odot c d = a e = a * 5 + 8 ...
```



```
...
a = b ⊙ c
d = a
e = a * 5 + 8
...
```

Élő kód felderítése

- Dead code felderítés: liveness analysis
- Egy változó élő (live) a program egy pontján, ha a később következő kódban előbb olvassák ki az értékét legalább egyszer, minthogy felülírnák azt
- Dead code szűrés ennek megfelelően:
 - > Minden változóra liveness számítás
 - > Minden olyan értékadás törlése, ami nem élő változónak ad értéket
- Fordított sorrendben dolgozzuk fel az alapblokk utasításait
- Néhány változó alapesetben élőnek számít (pl. kimenetet befolyásolja)

Élő kifejezések

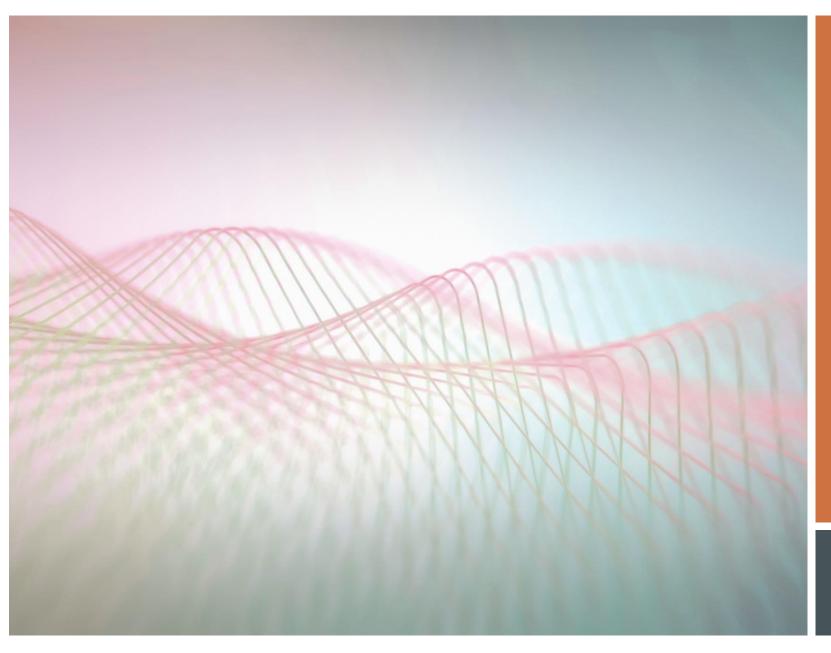
```
{ b }
a = b;
{ a, b }
{ a, b }
d = a + b;
{ a, b, d }
e = d;
{ a, b, e }
d = a;
{ b, d, e }
{ b, d }
```

Élő kifejezések

```
{ b }
a = b;
{ a, b }
d = a + b;
{ a, b, d }
{ a, b }
d = a;
{ b, d }
```

Élő kifejezések

```
{ b }
a = b;
{ a, b }
{ a, b }
d = a;
{ b, d }
```



Kód áthelyezés

Kódáthelyezés (code motion)

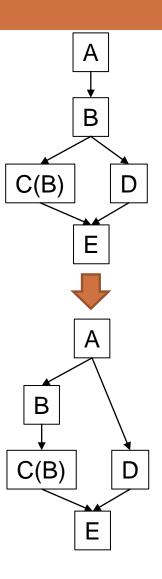
- Kódsüllyesztés (code sinking)
- Kódfaktorizálás (code factoring)
- Kódütemezés (code scheduling)
- Invariáns ciklusrészlet mozgatás (loop invariant code motion)

Kódsüllyesztés

- Az utasításokat csak ott hajtjuk végre, ahol szükség van rájuk
 - Hasonlít a dead code-ra, de mellékhatással járó utasításoknál is használható

```
...
    b=5;
    if (a>5) { write(b); } else { write("none"); }
...

...
    if (a>5) { b=5; write(b); } else { write("not ok"); }
...
```



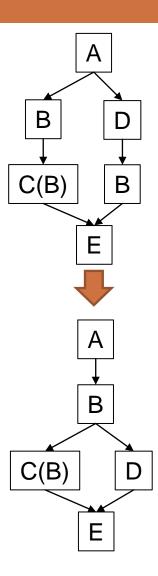
Kódfaktorizálás

- Közös utasításokat a közös ágban hajtjuk végre
 - > A kódsüllyesztés "ellentéte"
 - Syakran kisebb részekre bontjuk a kódot (faktorizáljuk)

```
...
  if (a>b) { c=5; write(c); } else { write("none"); c=5; }
...
```



```
...
    c=5;
    if (a>b) { write(c); } else { write("none"); }
...
```

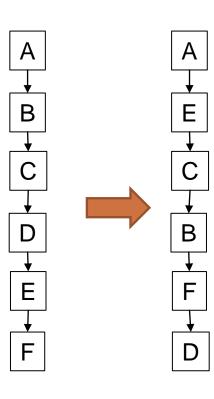


Kódütemezés

- Kerüljük el a hosszú várakozási sorokat!
 - > Párhuzamos/hatékony végrehajtás gyorsabb más sorrendben
 - > Függőségi gráf optimalizálása

```
...
a=f(); b=a+1; c=f2(a); d=a+c; e=f3(); f=e+a;
...

a=f(); e=f3(); c=f2(a); b=a+1; f=e+a; d=a+c;
...
```



- Emeljük ki az invariáns kódokat a ciklus elé!
 - > Ne számoljuk ki minden körben, feleslegesen

```
...
  int i = 0;
  while (i < j) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
...
</pre>
...

...

int i = 0;
  a = b + c;
  while (i < j) {
    d[i] = i + a * a;
    ++i;
}
...
```

- Emeljük ki az invariáns kódokat a ciklus elé!
 - > Kiemelhetünk részben invariáns kódokat is

```
...
  int i = 0;
  while (i < j) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
...
</pre>
...
int i = 0;
    a = b + c;
    int const a' = a * a;
    while (i < j) {
        d[i] = i + a';
        ++i;
}
...
</pre>
```

- Emeljük ki az invariáns kódokat a ciklus elé!
 - > Kezelni kell, hogy nem biztos, hogy egyáltalán belelép a ciklusba a program

```
int i = 0;
while (i < j) {
   a = b + c;
   d[i] = i + a * a;
   ++i;
}
...</pre>
```

```
int i = 0;
if (i<j) {
   a = b + c;
   int const a' = a * a;
   while (i < j) {
      d[i] = i + a';
      ++i;
   }
}...</pre>
```

- Emeljük ki az invariáns kódokat a ciklus elé!
 - > Mi történik, ha az ciklus feltételnek van mellékhatása?

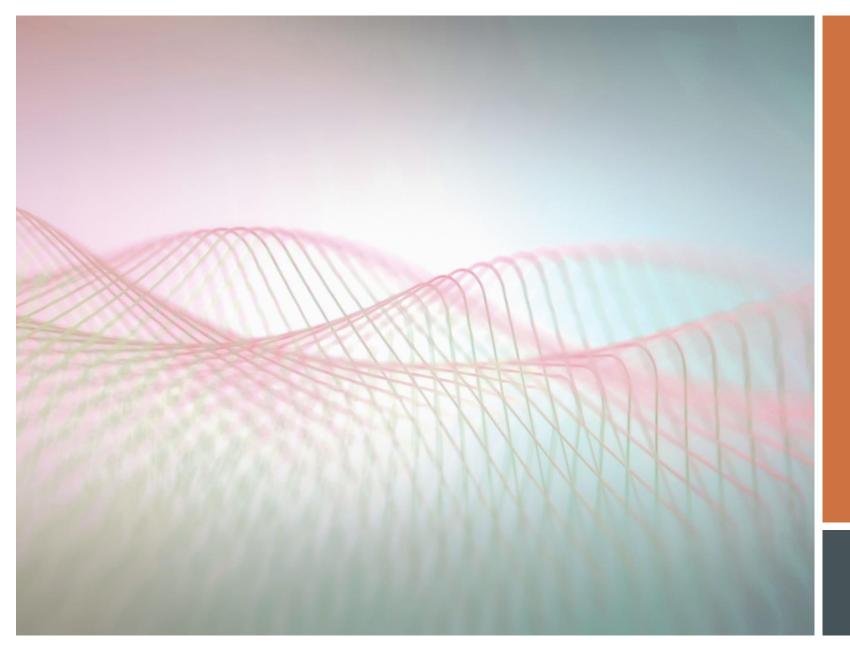
```
int i = 0;
while (fn(i)) {
   a = b + c;
   d[i] = i + a * a;
   ++i;
}
...
```

```
...
  int i = 0;
  if (fn(i)) {
    a = b + c;
    int const a' = a * a;
    while (fn(i)) {
       d[i] = i + a';
       ++i;
    }
}...
```

- Emeljük ki az invariáns kódokat a ciklus elé!
 - > Mi történik, ha a ciklus feltételnek van mellékhatása?

```
int i = 0;
while (fn(i)) {
   a = b + c;
   d[i] = i + a * a;
   ++i;
}
...
```

```
int i = 0;
if (fn(i)) {
   a = b + c;
   int const a' = a * a;
   do {
      d[i] = i + a';
      ++i;
   } while (fn(i));
}...
```



További optimalizációs technikák

Inline függvények használata

- Inline függvény hívás helyett bemásoljuk a függvény kódját
 - > Manuális v. automatikus művelet
 - > Nem azonos a makrókkal (ott a forráskód a fordítás előtt változik)

Előny

- Megspórolja a függvényhívás költségét (fv. pointerek, stack, regiszterek állítása)
- > Lokális/globális optimalizáció scope-ja nagyobbá válik
 - Invariáns kódrészletek kiszervezése (a ciklusokhoz hasonlóan)
 - Regiszter optimalizáció

Hátrány

- > Nő a memóriaméret (duplikált adatszerkezet)
- > Műveleti cache túllépés lehetséges

Regiszterkiosztás

- Regiszter gyors, könnyen elérhető, kis tároló
 - > Korlátozott mennyiség (< 32)</p>
 - > Minden élő változót be kellene tölteni
 - > Ami nem fér be → RAM
 - > Regiszterek néha nem függetlenek (pl. 32 bites használható 2x16 bitesként is)
- Mit vegyünk ki, mit tartsunk bent?
 - > NP teljes kérdés (gráf színezésre vezethető vissza, szín = regiszter)
 - > Újraszámolás (rematerialization) tárolás helyett (pl. konstans egész értékek)

További technikák

- Elemi technikák
 - > Elérhetetlen kód eliminálása
 - > Ciklusok kibontása, összevonása
 - > Indexhatár ellenőrzések elhagyása
- Gép/op. rendszerfüggő optimalizációk (pl. utasítás választás)
- Domain-függő optimalizálás

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás



Obfuszkáció

- Művelet, ami megnehezíti a program
 - > Működésének megértését
 - > Visszafejtését (gépi/köztes kódból)
 - > Elemzését
- Főként védekezésként
 - > Biztonsági hibák ellen
 - > Lopás / másolás ellen
- Csak megnehezíteni tudjuk a visszafejtést, meggátolni nem!
- Hogyan működik?
 - > Hasonlóan az optimalizációhoz
 - > Erősen függ a lehetőségektől (idő, visszafejthetetlenség fontossága, stb.)

Technikák

- Név obfuszkáció (lexikai átalakítás)
- Adat obfuszkáció (adatszerkezetek módosítása)
- Control flow obfuszkáció
- Debug információ obfuszkálás

Név obfuszkálás

- Beszédes azonosítók (osztályok, metódusok, változók, függvények, stb.)
 cseréje értelmetlen szövegre
- Korlátozások
 - > Beépített osztályok, API-k neve fix
 - > Szerializálandó osztályok neve fix
 - > Natív elérés és reflection esetén is nagyon trükkös

Adat obfuszkálás

- Megváltoztatja az adatok tárolásának a módját a memóriában
- Módszerek
 - > Kódolás (encoding) módjának változtatása
 - > Adataggregálás (tömbök, kollekciók)
 - > Megváltoztatni az adat szerepét (pl. lokális vs globális)

Példa: név és adat obfuszkálás

```
function foo( arg1)
{
  var myVar1 = "some string"; //first comment
  var intVar = 24 * 3600; //second comment
  /* here is
     a long multi-line comment . . . */
  document. write( "vars are:" + myVar1 + " " + intVar + " " + arg1);
};
```



```
function z001c775808( z3833986e2c) { var z0d8bd8ba25= "\x73\x6f\x6d\x65\x20\x73\x74\x72\x69\x6e\x67"; var z0ed9bcbcc2= (0x90b+785-0xc04)* (0x1136+6437-0x1c4b); document. write( "\x76\x61\x72\x73\x20\x61\x72\x65\x3a"+ z0d8bd8ba25+ "\x20"+ z0ed9bcbcc2+ "\x20"+ z3833986e2c);};
```

Példa: név és adat obfuszkálás

- Változók, azonosítók:
 - > foo \rightarrow z001c775808
 - $> arg1 \rightarrow z3833986e2c$
 - > myvar1 \rightarrow z0d8bd8ba25
 - > intvar → z0ed9bcbcc2
- Integer számok ábrázolása:
 - $> 20 \rightarrow (0x90b+785-0xc04)$
 - $> 3600 \rightarrow (0x1136+6437-0x1c4b)$
- Kiírás:
 - \rightarrow "vars are" \rightarrow \x76\x61\x72\x73\x20\x61\x72\x65\x3a
 - > Space $\rightarrow \x20$

```
var intVar = 24 * 3600;
//second comment

/* here is
    a long multi-line
comment ... */

document.write( "vars are:" +
    myVar1 + "" + intVar + ""
    + arg1);
};
```

var myVar1 = "some string";
//first comment

function foo(arg1)

```
function z001c775808( z3833986e2c) { var z0d8bd8ba25=
  "\x73\x6f\x6d\x65\x20\x73\x74\x72\x69\x6e\x67"; var z0ed9bcbcc2=
  (0x90b+785-0xc04)* (0x1136+6437-0x1c4b); document. write(
  "\x76\x61\x72\x73\x20\x61\x72\x65\x3a"+ z0d8bd8ba25+ "\x20"+
  z0ed9bcbcc2+ "\x20"+ z3833986e2c);};
```

Control Flow obfuszkálás

- A vezérlési folyam megváltoztatása
- Azonos eredmény, de nehezebben érthető kód
- Módszerek
 - > Módosított vezérlés, pl. inline metódusok hívása metódushívás helyett
 - > Utasítássorrend megváltoztatása
 - > Számítások átalakítása
 - Elérhetetlen kód beszúrása
 - Feltétel nélküli ugrások elhelyezése
 - Utasításblokkok kettévágása feltételes utasítássá
 - Mindig igaz/hamis elágazásblokkok

Példa: Control Flow obfuszkálás

```
public int CompareTo(Object o)
{
  int n = occurrences - ((WordOccurrence)o).occurrences;
  if (n == 0)
    {
        n = String.Compare(word,((WordOccurrence)o).word);
    }
    return(n);
}
```



```
public virtual int _a(Object A_0)
{
  int local0; int local1;
  local0 = this.a - (c) A_0.a;
  if (local0 != 0) goto i0;
  goto i1;
  while (true) {
     return local1;
     i0: local1 = local0;}
  i1: local0 = System.String.Compare(this.b, (c) A_0.b); goto i0;
}
```

Debug információ obfuszkálása

- Debug információk eltávolítása
 - > Stack trace
 - > Line number
 - > Fájl nevek, etc.

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás



Kódgenerálás

- Kódgenerálás: a fordító belső reprezentációjából (optimalizált köztes kód) futtatható kód előállítása
 - Nem feltétlenül bináris gépi kód a cél!
- Bemenet jellege szerint
 - > 3-című kód (Three-Address Code, 3AC)
 - > Szintaxisfa
 - > stb.
- Kimenet jellege szerint
 - > Gépi kód
 - > Köztes kód (pl. LLVM, IL)
 - > Magas szintű programozási nyelvű kód (transpiler)

Kódgenerálás - gépi kód

Kódgenerálás

- > A cél architektúra által támogatott műveletekre alakítás
- > Regiszterfoglalások menedzselése RegisterDescriptor + getReg
- > Címadminisztráció (változók címe, változhat a futás alatt) AddressDescriptor

x = y op z

- > getReg hívás az eredmény tárolásának (L) címéhez
- > Y címének felderítése (AddressDescriptor), majd másolás: MOV y L
- > Z címének felderítése (AddressDescriptor), majd műveletvégzés: OP z L
- > L-ben elérhető az eredmény, ha L regiszter, akkor x leírójába beírni, hogy L tárolja

Kódgenerálás - gépi kód

Közvetlenül futtatható a generálás eredménye

Előnyök

- > Optimális gyorsaság és méret érhető el vele
- > Gyors, teljesen ki tudja használni az archiektúra sajátosságait
- > Bármi leírható vele, nincsenek nyelvi korlátok

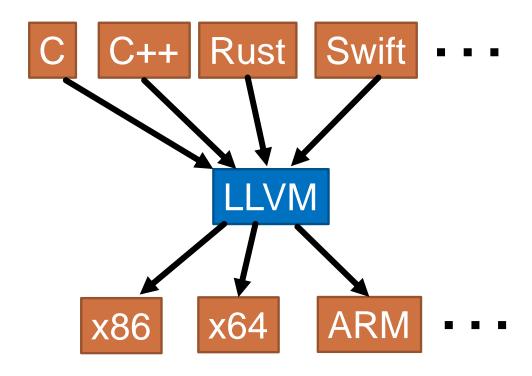
Hátrányok

- > Alacsonyszintű, sok munka megírni
- > Minden ellenőrzést (pl. stack overflow) nekünk kell végezni
- > A generált kódban a hibakeresés nehéz

Kódgenerálás - köztes kód

LLVM

- > Frontend: platformfüggetlen SSA utasítás lista
- > Backend: platformspecifikus bináris kód
- > ~ "olvasható assembly"
- > végtelen virtuális regiszter
- > saját platformfüggetlen típusrendszer
- > beépített optimalizálók (pl. dead code, common subexpression)



LLVM - példa

```
function int factorial(int n) {
   if (n==0) {
     1
   } else {
     n * factorial(n - 1)
   }
}
```

```
define i32 @factorial(i32) {
entry:
 ext{deg} = icmp eq i32 %0, 0 // n == 0
br il %eq, label %then, label %else
then:
                   ; preds = %entry
br label %ifcont
else:
%2 = call i32 @factorial(i32 %sub) // factorial(n-1)
%mult = mul i32 %0, %2 // n * factorial(n-1)
br label %ifcont
ifcont:
         ; preds = %else, %then
%iftmp = phi i32 [ 1, %then ], [ %mult, %else ]
ret i32 %iftmp
```

Kódgenerálás - köztes kód

- Common Intermediate Language (CIL)
 - > Objektumorientált (objektumok, tagfüggvények, tagváltozók)
 - > Stack-alapú (regiszterek helyett)
 - > Hardver és op. rendszer független
 - > Meta-adat tárolására képes
- Just-in-Time (JIT) compiler futtatja
 - > Ahead-of-time fordítás is elérhető
 - > Biztonsági ellenőrzések
- Disassembler segítségével magas szintű programnyelvekre is alakítható

IL - példa

```
function int factorial(int n) {
  if (n==0) {
    1
  } else {
    n * factorial(n - 1)
  }
}
```

```
.method public hidebysig
instance int32 factorial (int32 n) cil managed {
    // Method begins at RVA 0x2064
    // Code size 31 (0x1f)
    .maxstack 4
    .locals init ([0] bool,[1] int32)

    // {
    IL_0000: nop

    // if (n == 0)
    IL_0001: ldarg.1
    IL_0002: ldc.i4.0
    IL_0003: ceq
    IL_0005: stloc.0
    IL_0006: ldloc.0
    IL_0007: brfalse.s IL_000e
```

```
// return 1;
 IL 0009: nop
 IL 000a: ldc.i4.1
 IL 000b: stloc.1
 // (no C# code)
 IL 000c: br.s IL 001d
 // return n * factorial(n - 1);
  IL 000e: nop
 IL 000f: ldarg.1
 IL 0010: ldarg.0
 IL 0011: ldarg.1
 IL 0012: ldc.i4.1
 IL 0013: sub
 IL 0014: call instance int32
                           Host::factorial(int32)
  IL 0019: mul
 IL 001a: stloc.1
  // (no C# code)
 IL 001b: br.s IL 001d
 IL 001d: ldloc.1
 IL 001e: ret
} // end of method Host::factorial
```

Kódgenerálás - köztes kód

Előnyök

- > Könnyebb generálni, mint gépi kódot, olvashatóbb emberi felhasználásra
- > Kevesebb technikai nehézség (pl. regiszter allokáció)
- > Hatékony tud lenni, mivel alacsonyszintű
- > Több platformra fordítható

Hátrányok

- > Kell hozzá egy speciális compiler
- > A célkód (köztes kód) előállítása nem egyszerű

Kódgenerálás - transpiler

- Transpiler: más, jellemzően magas absztrakciós szintű célnyelvre fordítunk
 - > Bejárjuk az annotált szintaxisfát és tipikusan sablonnal kódot generálunk
 - > Tipikus megoldás: minden AST elem képes a saját kódját előállítani, hierarchikus dekompozíció
 - > Több fordító is "sorba köthető" egymás után

```
if (x > 5) then
begin
while (y < z) do
begin
y := x;
end
end</pre>
```



```
if (x > 5)
 while (y < z) {
  y = x;
}</pre>
```

Kódgenerálás - transpiler

Előnyök

- > Könnyű megírni a kódgenerátort
- > A gépi kód a célnyelvű, generált forrás fordításával áll elő
 - Rábízhatjuk magunkat a célnyelv fordítójára
 - Külső kód optimalizálás (pl. Visual Studio, GCC)
 - Biztonsági ellenőrzések (pl. memória túlcímzés)
- > Könnyebb ellenőrizni a generált kód szemantikáját (C# vs. Assembly)
- > A generált kódot könnyű integrálni meglévő alkalmazásokba/eszközökbe

Hátrányok

- > Nem lehet annyira optimalizálni, mint a gépi kódot
- > A célnyelv képességei korlátozzák a lehetőségeket

Kódgenerálás után: linkelés, buildelés

- Kódgenerálás kimenete nem mindig futtatható magában: több modul ('object' file)
- Linkelés: az object fájlok összefűzése futtatható állománnyá
 Buildelés: az összelinkelt fájlok futtatható állománnyá alakítása
- Linkelés előnyök
 - > Egyetlen monolitikus állomány helyett több kisebb (kevésbé komplex)
 - > Egyszerűbb hibakezelés és inkrementális fordítás
 - > Lefordított object fájlok újrahasznosítása

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás



Szöveges szerkesztők (Editorok)

- Szöveges nyelvek jó tool support
 - Írhatnánk Notepad-ben is, de nem ajánlott ☺



- Vannak kiforrottabb szövegszerkesztők (Pl. Vim, Emacs, Atom)
 - De ezeket összekötni a nyelvünkkel nem túl egyszerű
- Fejlesztői környezetek (IDE)
 (Pl. VSCode, Eclipse, Eclipse Theia, IntelliJ IDEA, NetBeans)
 - Ezek közül több kiterjeszthető (plugin, extension, stb.), ami megkönnyíti az összekötést
- Nyelv és editor összekötése
 - A fordítás fázisaival összhangban (elsősorban szemantikai elemzésnél)

∄O THEIA



Szöveges szerkesztők (Editorok)

- Editor funkciók
 - Syntax highlighting
 - Code completion
 - Hibák jelzése
 - Refaktorálás támogatása
 - Folding
 - Quick fixek
 - Stb.

```
//app/database.ts
import { Tweet, TweetWithId } from "./models";
import { v4 as uuidv4 } from 'uuid';

function generateTweetId() : string {
    return uuid();
}

everyort class Database { ...
}

export class Database { ...
}
```

```
Device Window can be OPEN, SHUT
Device Heating can be ON, OFF
Rule 'Close Window, when heating turned on'
when Heating.ON
then Window.SHUT
Rule 'Switch off heating, when windows gets opened'
when Window.OPEN
then Heating.OFF
     Heating.OFF
                                      State
     Heating.ON
                                      State
     Window.OPEN
                                      State
     Window.SHUT
                                      State
```

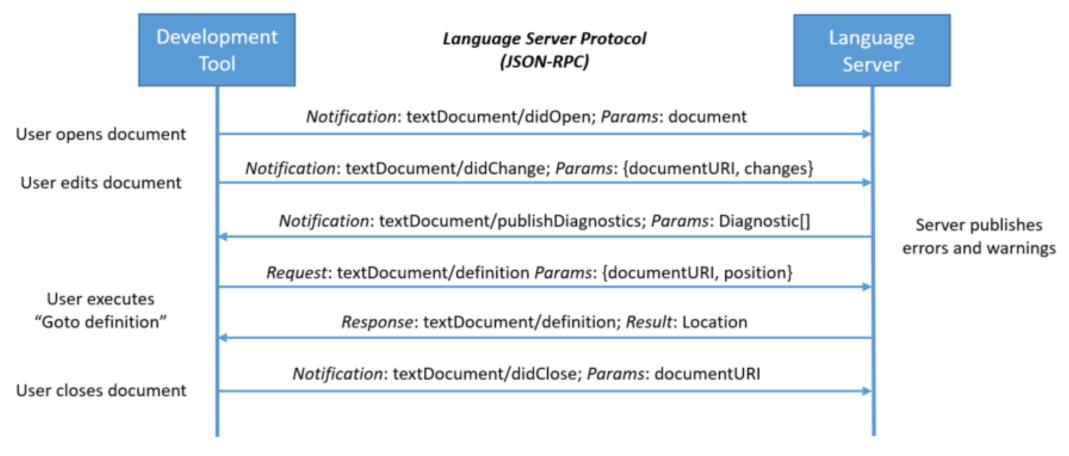
Forrás:

https://www.eclipse.org/Xtext/

Language Server Protocol (LSP)

- JSON-RPC alapú protokoll
- Szöveges editorok és language serverek közötti kommunikáció
- Főbb editor funkciók támogatása
 - Syntax highlighting, hibák jelzése, code completion, refaktorálás, stb.
- Miért jó ez nekünk?
 - Egyszer kell megírni, több editorral is összeköthető
 - Sok népszerű editor támogatja (Pl. VSCode, Monaco, Eclipse IDE, Eclipse Theia)
 - Sok nyelvhez van létező Language Server implementáció
 - https://langserver.org/

Language Server Protocol (LSP)



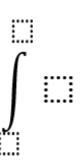
Forrás: https://microsoft.github.io/language-server-protocol/overviews/lsp/overview/

Projekciós Editorok

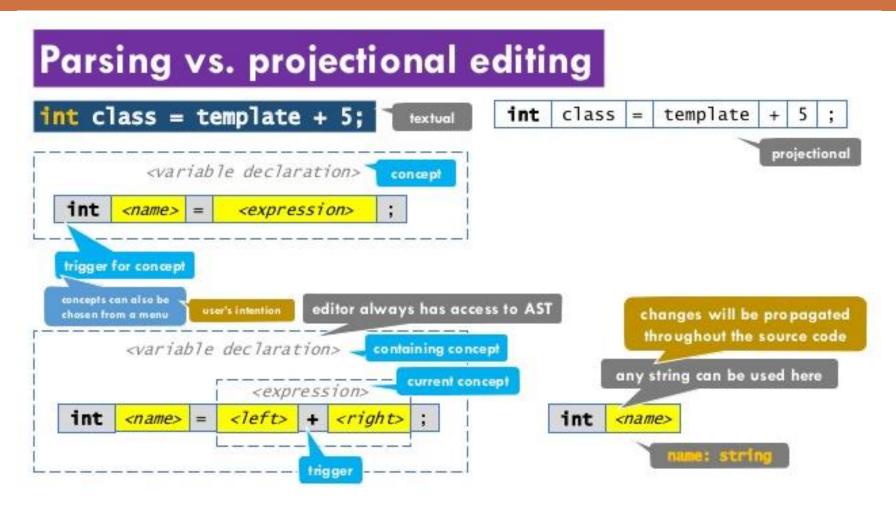
- Hagyományos editorok
 - Amikről eddig szó volt
 - Bevált, sok helyen használják
 - Bármilyen szövegszerkesztő használható (ajánlott editor funkciókkal)
- Projekciós editorok
 - A szintaxisfa elemei közvetlenül vizualizálva vannak
 - Nem kell szintaxisfát építeni!
 - Speciális tooling kell hozzá
 - PI. Jetbrains MPS, Gentleman

Projekciós Editorok – példa

- Szemantikus modell
 - intervallum alsó, felső határa
 - integrálandó kifejezés
- Konkrét kifejezés: $\int_{-\infty}^{\infty} e^{-x^2} dx$
- Közvetlenül leképezhető a szemantikus modellre

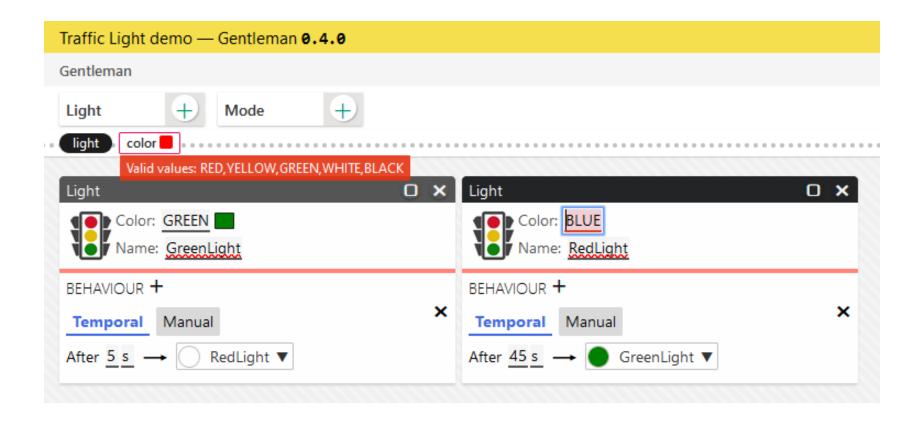


Projekciós Editorok – JetBrains MPS



Forrás: Mikhail Barash: Reflections on teaching JetBrains MPS within a university course

Projekciós Editorok – Gentleman



Forrás: https://geodes.iro.umontreal.ca/gentleman/demo/traffic-light/index.html



Köszönöm a figyelmet!