Modellalapú szoftverfejlesztés

VI. előadás

Optimalizáció,
Obfuszkáció,
Kódgenerálás

Dr. Mezei Gergely

Fordítás fázisai

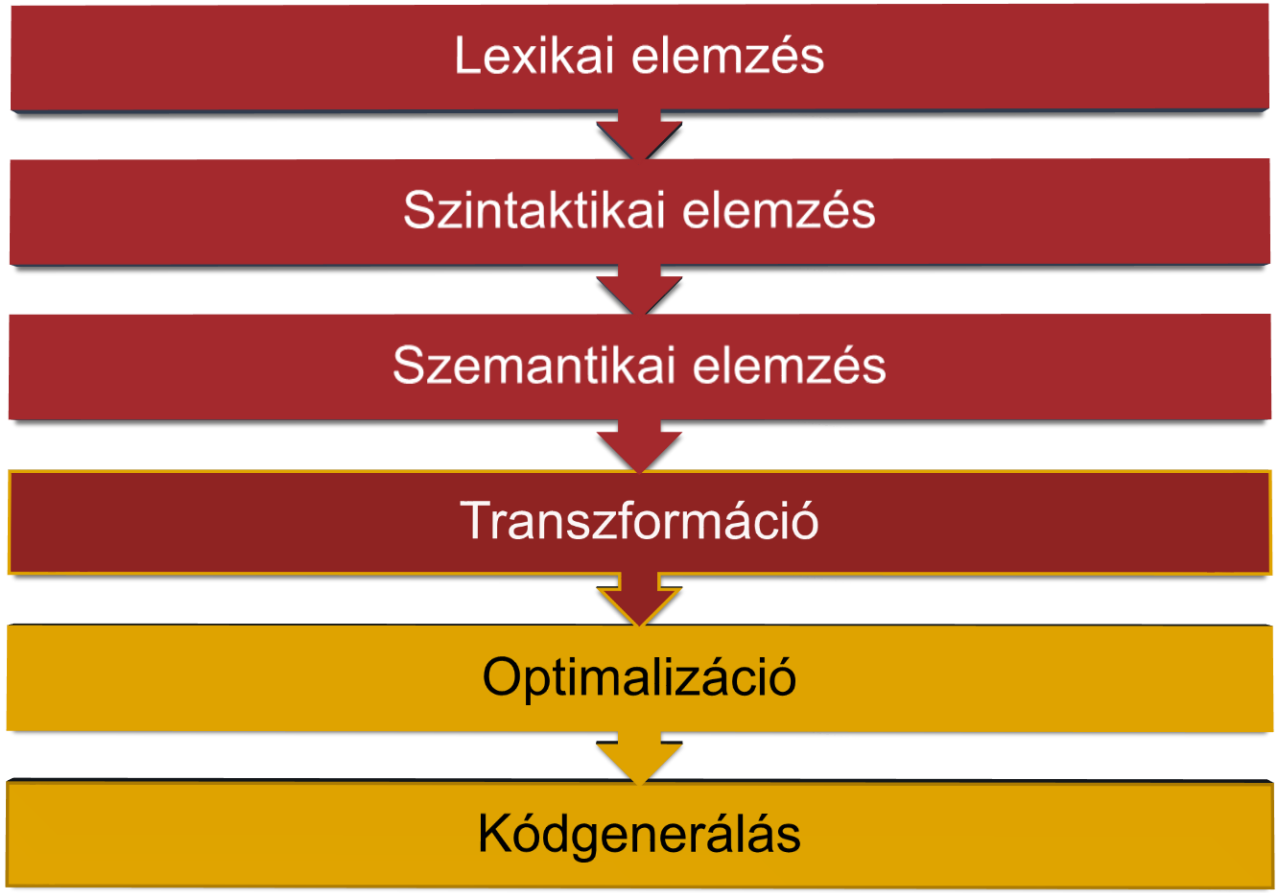

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció (folytatás)

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás

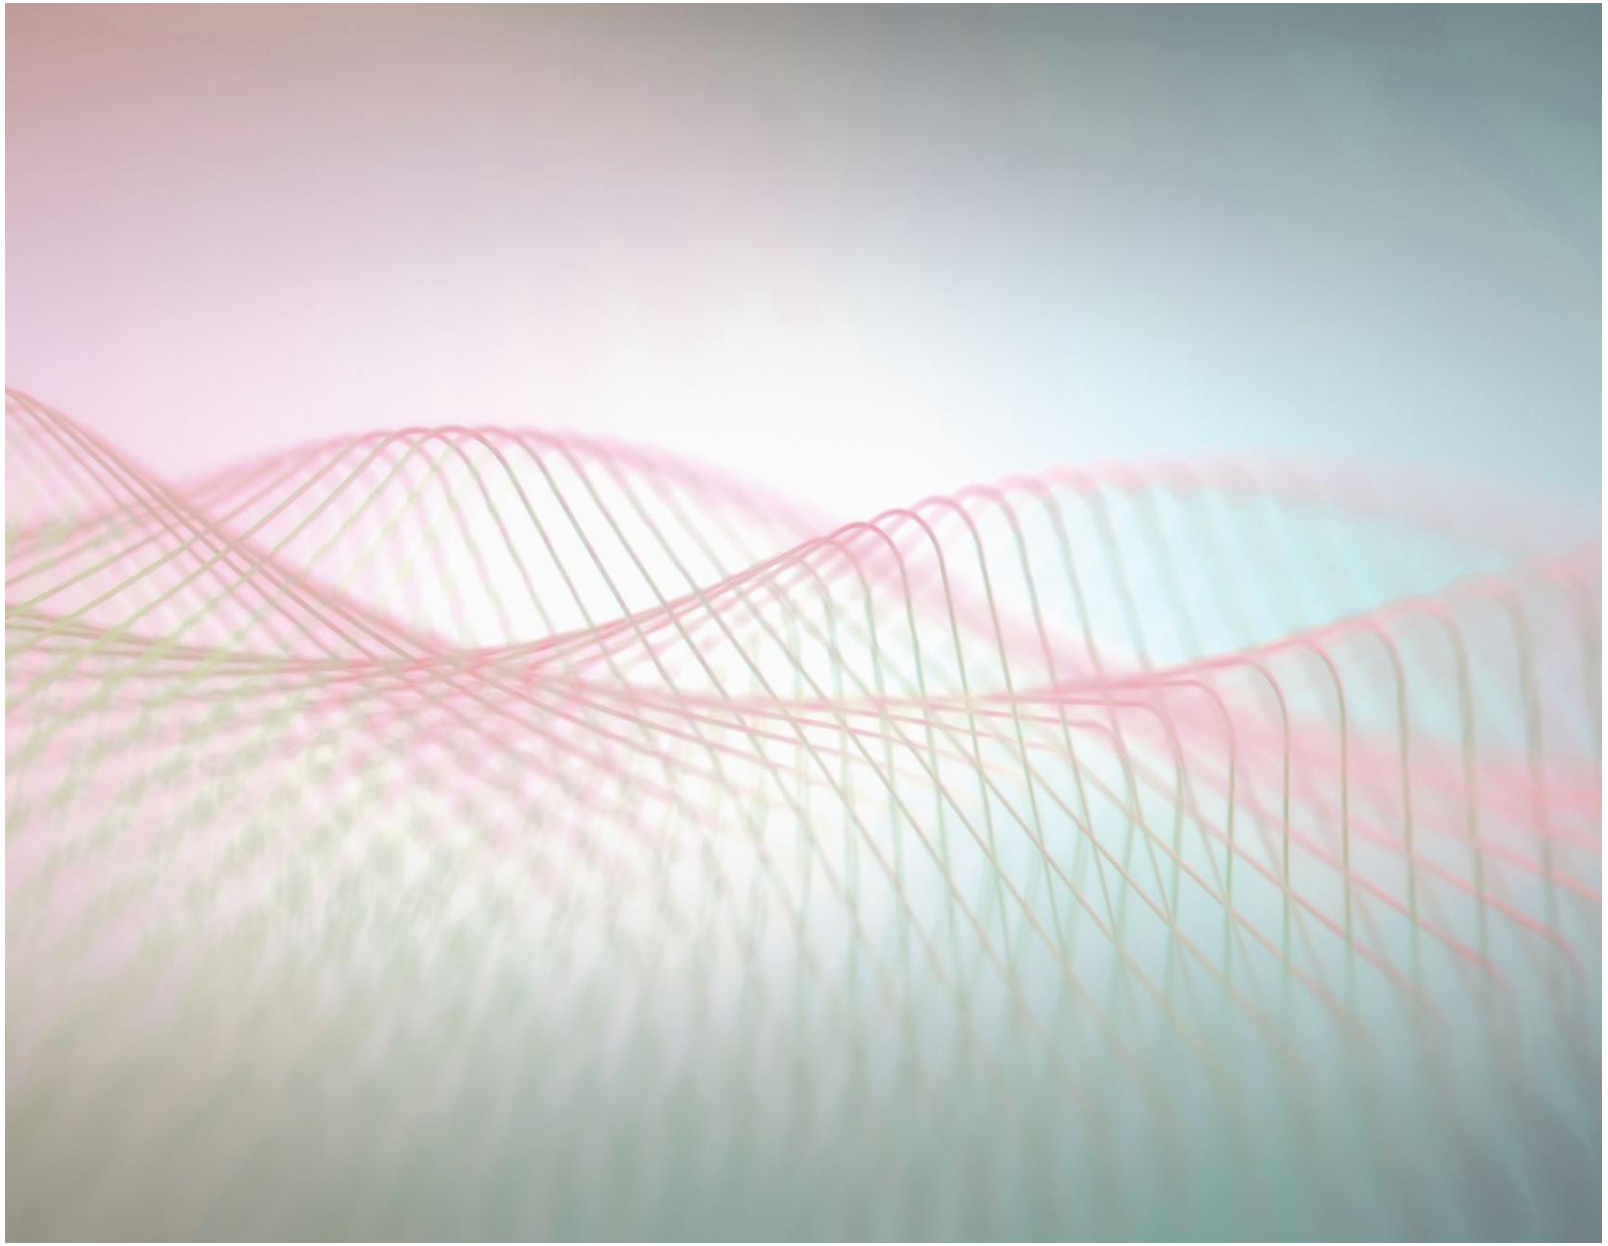

Adatfolyam optimalizáció

Adatfolyam optimalizáció

- Közös kifejezés (common subexpression)
- Konstans/változó propagáció (constant/copy propagation)
- Elérhető kifejezések
- Halott kód (dead code)
- Élő változók felderítése

Csak alapblokkon belül (lokális)!

Common subexpression

- Ne számoljuk ki kétszer ugyanazt!
  - Ha az operandusok nem változtak és a művelet mellékhatás mentes

```
…
  a = b ⊙ c + 5
  e = (b ⊙ c) * 2
…
```

```
…
  tmp = b ⊙ c
  a = tmp + 5
  e = tmp * 2
…
```

Constant propagation

- Ha egy változóba konstans érték kerül, akkor a változót lecserélhetjük az értékre

```
…
  a = 7
  b = a ⊙ 3
  …
  if (a > 4) { write(“.”); }
…
```

```
…
  a = 7
  b = 7 ⊙ 3
  …
  if (7>4) write(“.”);
…
```

Copy propagation

- Ha két változó értéke megegyezik, kicserélhetőek

```
…
  a = b ⊙ c
  d = a
  e = d * 5 + 8
…
```

```
…
  a = b ⊙ c
  d = a
  e = a * 5 + 8
…
```

Optimalizáció - példa

```
…
b = a * a;
c = a * a;
d = b + c;
e = 1;
f = b + b;
g = f * e;
…
```

Elérhető kifejezések

- *Elérhető* kifejezés (available expression): ha van aktuálisan olyan változó, ami a kifejezés értékét tartalmazza, akkor a kifejezés lecserélhető a változóra
- Elérhető kifejezések felderítése
  - Kezdetben üres halmaz
  - a = b $\odot$ c kifejezésnél
    - Az a-t tartalmazó kifejezéseket kivesszük
    - a= b $\odot$ c kifejezést betesszük

Elérhető kifejezések alkalmazása

{ }

```
a = b;
```

{ a = b }

```
c = a;
```

{ a = b, c = b }

```
d = a + b;
```

{ a = b, c = b, d = a + b }

```
e = d;
```

{ a = b, c = b, d = a + b, e = a + b }

```
d = a;
```

{ a = b, c = b, d = b, e = a + b }

```
f = e;
```

{ a = b, c = b, d = b, e = a + b, f = a + b }

Dead code

- Ha egy értékadás bal oldalán szereplő változó értékét sehol nem olvassuk ki, akkor az értékadás törölhető

```
…
  a = b ⊙ c
  d = a
  e = a * 5 + 8
…
```

```
…
  a = b ⊙ c
  ~~d = a~~
  e = a * 5 + 8
…
```

Élő kód felderítése

- Dead code felderítés: **liveness analysis**
- Egy változó *élő* (live) a program egy pontján, ha a később következő kódban előbb olvassák ki az értékét legalább egyszer, minthogy felülírnák azt
- Dead code szűrés ennek megfelelően:
  - Minden változóra liveness számítás
  - Minden olyan értékadás törlése, ami nem élő változónak ad értéket
- Fordított sorrendben dolgozzuk fel az alapblokk utasításait
- Néhány változó alapesetben élőnek számít (pl. kimenetet befolyásolja)

Élő kifejezések

```
{ b }
a = b;
{ a, b }


{ a, b }
d = a + b;
{ a, b, d }
e = d;
{ a, b, e }
d = a;
{ b, d, e }


{ b, d }
```

Élő kifejezések

```
{ b }
a = b;
{ a, b }
d = a + b;
{ a, b, d }

{ a, b }
d = a;
{ b, d }
```

Élő kifejezések

{ b }

```
a = b;
```

{ a, b }

{ a, b }

```
d = a;
```

{ b, d }

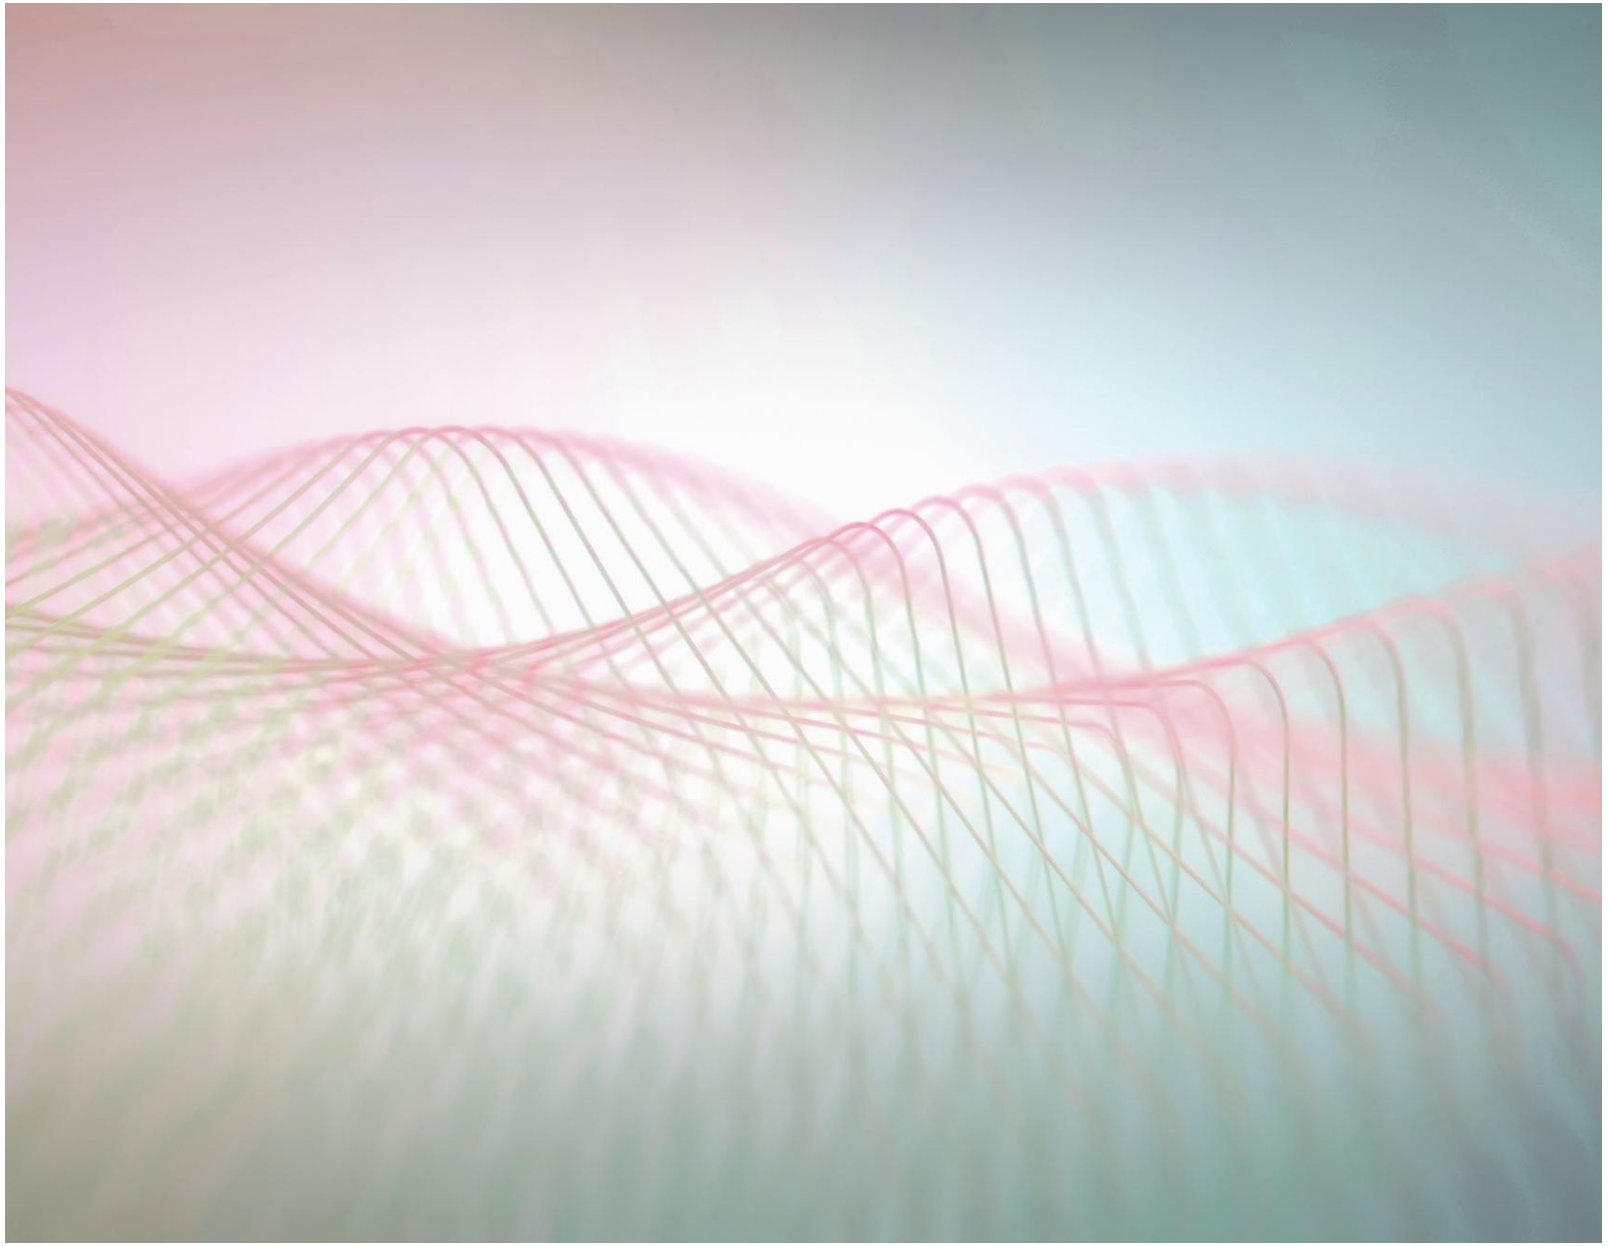

Kód áthelyezés

Kódáthelyezés (code motion)

- Alapblokkon kívüli optimalizáció
- Kódsüllyesztés (code sinking)
- Kódfaktorizálás (code factoring)
- Kódütemezés (code scheduling)
- Invariáns ciklusrészlet mozgatás (loop invariant code motion)

Kódsüllyesztés

- Az utasításokat csak ott hajtjuk végre, ahol szükség van rájuk
  - Hasonlít a dead code-ra, de mellékhatással járó utasításoknál is használható

```
…
  b=5;
  if (a>5) { write(b); } else { write("none"); }
…
```

```
…
  if (a>5) { b=5; write(b); } else { write("not ok"); }
…
```

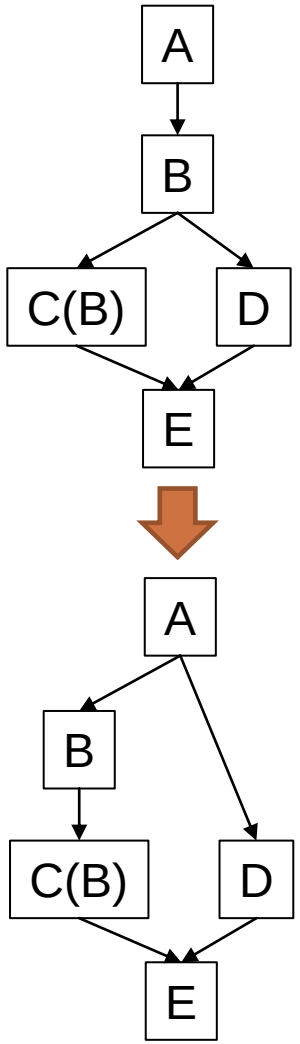

Kódfaktorizálás

- Közös utasításokat a közös ágban hajtjuk végre
  - A kódsüllyesztés “ellentéte”
  - Gyakran kisebb részekre bontjuk a kódot (faktorizáljuk)

```
…
  if (a>b) { c=5; write(c); } else { write(“none”); c=5; }
…
```

```
…
  c=5;
  if (a>b) { write(c); } else { write(“none”); }
…
```

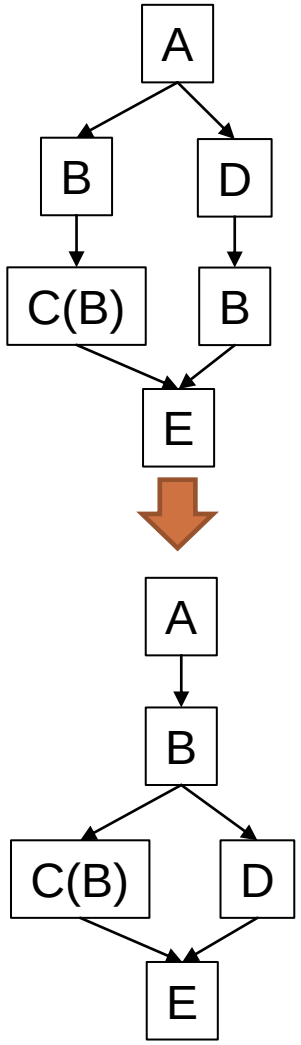

Kódütemezés

- Kerüljük el a hosszú várakozási sorokat!
  - > Párhuzamos/hatékony végrehajtás gyorsabb más sorrendben
  - > Függőségi gráf optimalizálása

```
…
  a=fv(); b=a+1; c=f2(a); d=a+c; e=f3(); f=e+a;
…
```

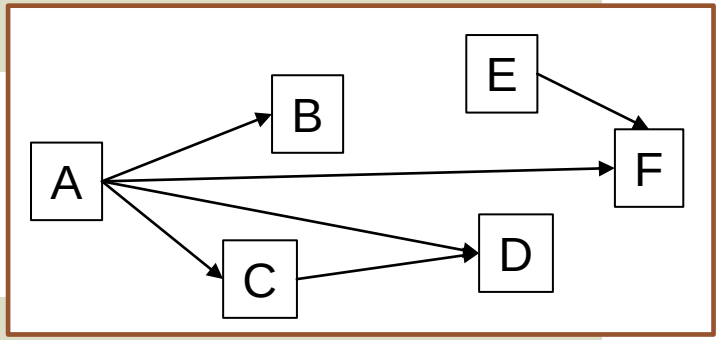


```
…
  a=fv(); e=f3(); c=f2(a); b=a+1; f=e+a; d=a+c;
…
```

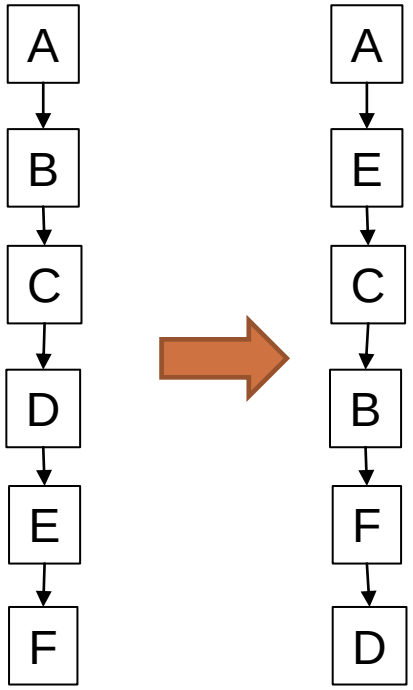

Invariáns ciklusrészlet mozgatás

- Emeljük ki az invariáns kódokat a ciklus elé!
  - > Ne számoljuk ki minden körben, feleslegesen

```
…
  int i = 0;
  while (i < j) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
…
```

```
…
  int i = 0;
  a = b + c;
  while (i < j) {
    d[i] = i + a * a;
    ++i;
}
…
```

Invariáns ciklusrészlet mozgatás

- Emeljük ki az invariáns kódokat a ciklus elé!
  - Kiemelhetünk részben invariáns kódokat is

```
…
  int i = 0;
  while (i < j) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
…
```

```
…
  int i = 0;
  a = b + c;
  int const a' = a * a;
  while (i < j) {
    d[i] = i + a';
    ++i;
}
…
```

Invariáns ciklusrészlet mozgatás

- Emeljük ki az invariáns kódokat a ciklus elé!
  - Kezelni kell, hogy nem biztos, hogy egyáltalán belelép a ciklusba a program

```
…
  int i = 0;
  while (i < j) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
…
```

```
…
  int i = 0;
  if (i<j) {
    a = b + c;
    int const a’ = a * a;
    while (i < j) {
      d[i] = i + a’;
      ++i;
   }
}…
```

Invariáns ciklusrészlet mozgatás

- Emeljük ki az invariáns kódokat a ciklus elé!
  - > Mi történik, ha az ciklus feltételnek van mellékhatása?

```
…
  int i = 0;
  while (fn(i)) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
…
```

```
…
  int i = 0;
  if (fn(i)) {
    a = b + c;
    int const a’ = a * a;
    while (fn(i)) {
      d[i] = i + a’;
      ++i;
   }
}…
```

Invariáns ciklusrészlet mozgatás

- Emeljük ki az invariáns kódokat a ciklus elé!
  - Mi történik, ha a ciklus feltételnek van mellékhatása?

```
…
  int i = 0;
  while (fn(i)) {
    a = b + c;
    d[i] = i + a * a;
    ++i;
}
…
```

```
…
  int i = 0;
  if (fn(i)) {
    a = b + c;
    int const a’ = a * a;
    do {
      d[i] = i + a’;
      ++i;
    } while (fn(i));
}…
```

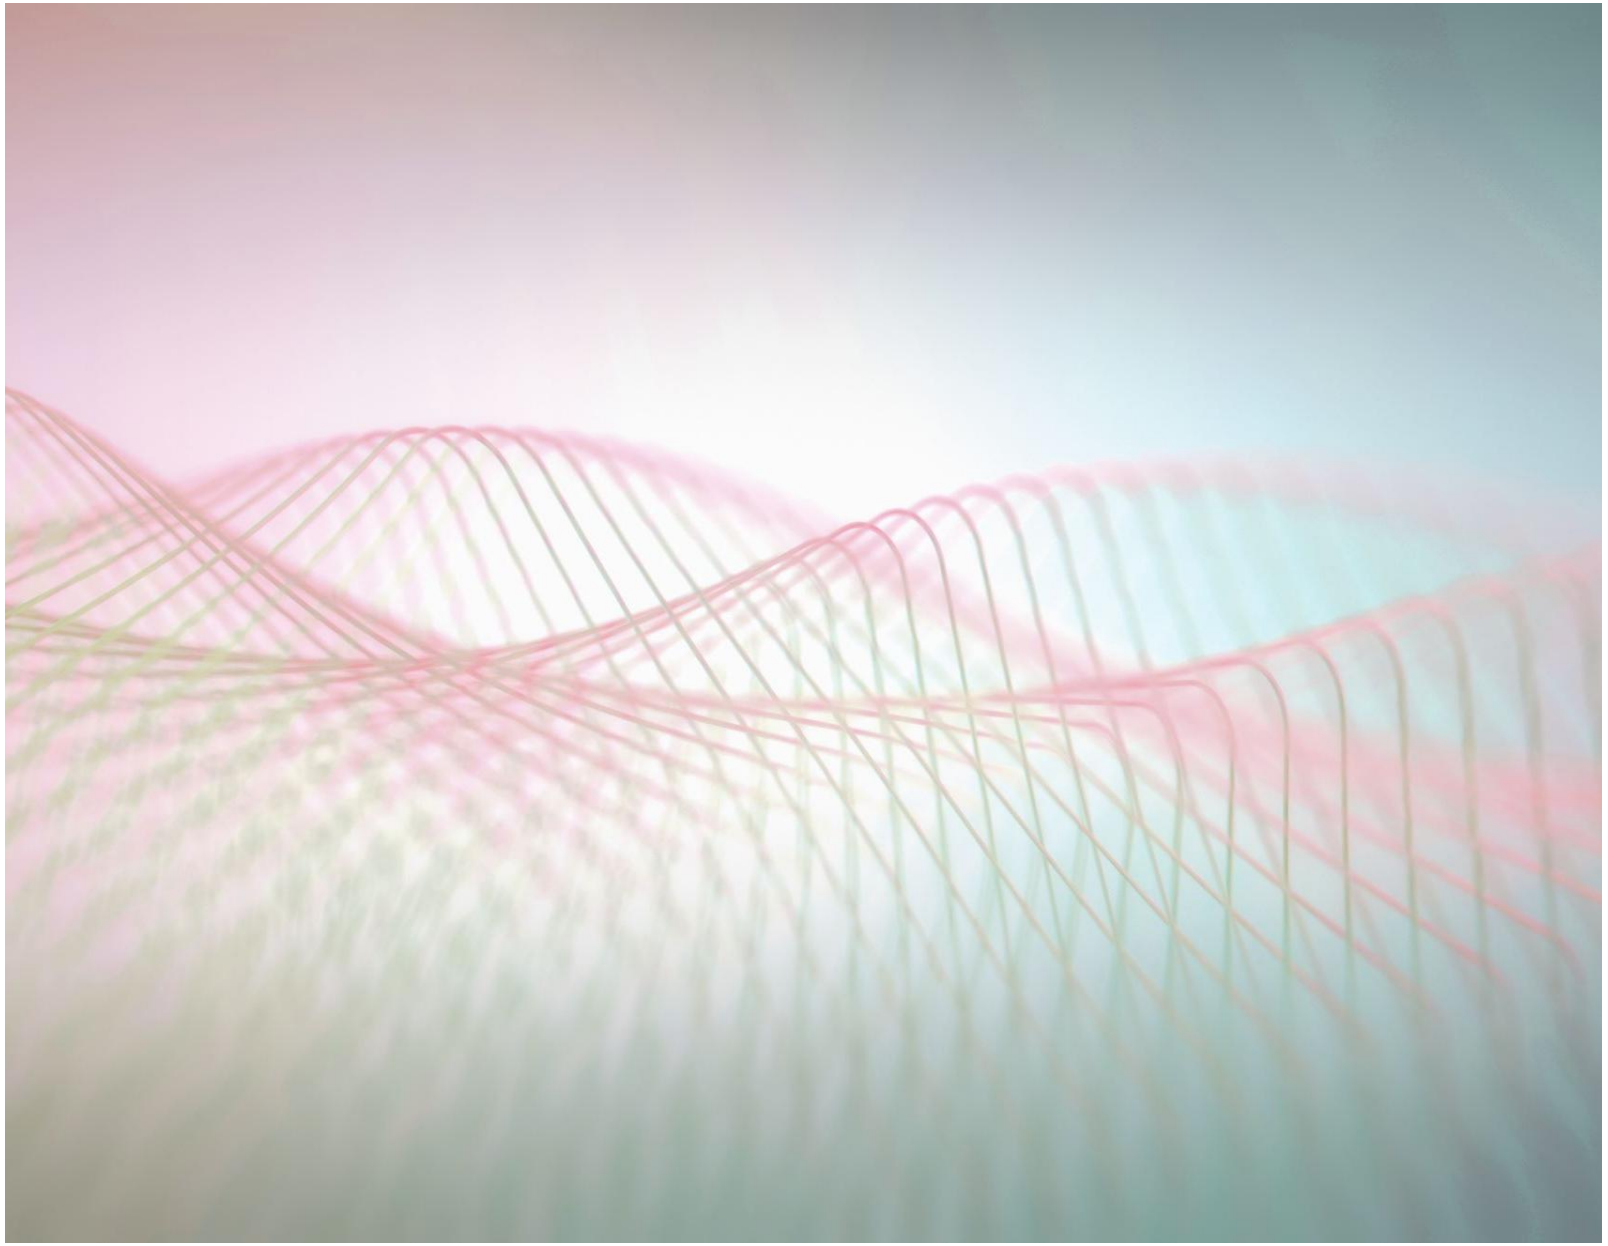

További optimalizációs technikák

Inline függvények használata

- Inline függvény – hívás helyett bemásoljuk a függvény kódját
  - Manuális v. automatikus művelet
  - Nem azonos a makrókkal (ott a forráskód a fordítás előtt változik)
- Előny
  - Megspórolja a függvényhívás költségét (fv. pointerek, stack, regiszterek állítása)
  - Lokális/globális optimalizáció scope-ja nagyobbá válik
    - Invariáns kódrészletek kiszervezése (a ciklusokhoz hasonlóan)
    - Regiszter optimalizáció
- Hátrány
  - Nő a memóriaméret (duplikált adatszerkezet)
  - Műveleti cache túllépés lehetséges

Regiszterkiosztás

- Regiszter – gyors, könnyen elérhető, kis tároló
  - Korlátozott mennyiség (< 32)
  - Minden élő változót be kellene tölteni
  - Ami nem fér be → RAM
  - Regiszterek néha nem függetlenek (pl. 32 bites használható 2x16 bitesként is)
- Mit vegyünk ki, mit tartsunk bent?
  - NP teljes kérdés (gráf színezésre vezethető vissza, szín = regiszter)
  - Újraszámolás (rematerialization) tárolás helyett (pl. konstans egész értékek)

További technikák

- Elemi technikák
  - Elérhetetlen kód eliminálása
  - Ciklusok kibontása, összevonása
  - Indexhatár ellenőrzések elhagyása
- Gép/op. rendszerfüggő optimalizációk (pl. utasítás választás)
- Domain-függő optimalizálás

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás

Obfuszkáció

- Művelet, ami megnehezíti a program
  - Működésének megértését
  - Visszafejtését (gépi/köztes kódból)
  - Elemzését
- Főként védekezésként
  - Biztonsági hibák ellen
  - Lopás / másolás ellen
- Csak megnehezíteni tudjuk a visszafejtést, meggátolni nem!
- Hogyan működik?
  - Hasonlóan az optimalizációhoz
  - Erősen függ a lehetőségektől (idő, visszafejthetetlenség fontossága, stb.)

Technikák

- Név obfuszkáció (lexikai átalakítás)
- Adat obfuszkáció (adatszerkezetek módosítása)
- Control flow obfuszkáció
- Debug információ obfuszkálás

Név obfuszkálás

- Beszédes azonosítók (osztályok, metódusok, változók, függvények, stb.) cseréje értelmetlen szövegre
- Korlátozások
  - Beépített osztályok, API-k neve fix
  - Szerializálandó osztályok neve fix
  - Natív elérés és reflection esetén is nagyon trükkös

Adat obfuszkálás

- Megváltoztatja az adatok tárolásának a módját a memóriában
- Módszerek
  - Kódolás (encoding) módjának változtatása
  - Adataggregálás (tömbök, kollekciók)
  - Megváltoztatni az adat szerepét (pl. lokális vs globális)

Példa: név és adat obfuszkálás

```
function foo( arg1)
{
  var myVar1 =  "some string";  //first comment
  var intVar =  24 *  3600; //second comment
  /* here is
       a long multi-line comment . . . */
  document. write( "vars are:" +  myVar1 +  " " +  intVar +  " " +  arg1) ;
} ;
```

```
function z001c775808( z3833986e2c) { var z0d8bd8ba25=
  "\x73\x6f\x6d\x65\x20\x73\x74\x72\x69\x6e\x67"; var z0ed9bcbcc2=
  (0x90b+785-0xc04)* (0x1136+6437-0x1c4b); document. write(
  "\x76\x61\x72\x73\x20\x61\x72\x65\x3a"+ z0d8bd8ba25+ "\x20"+
  z0ed9bcbcc2+ "\x20"+ z3833986e2c);};
```

Példa: név és adat obfuszkálás

- Változók, azonosítók:
  - foo → z001c775808
  - arg1 → z3833986e2c
  - myvar1 → z0d8bd8ba25
  - intvar → z0ed9bcbcc2
- Integer számok ábrázolása:
  - 20 → (0x90b+785-0xc04)
  - 3600 → (0x1136+6437-0x1c4b)
- Kiírás:
  - “vars are” → \x76\x61\x72\x73\x20\x61\x72\x65\x3a
  - Space → \x20

```
function foo( arg1)
{
  var myVar1 =  "some string";
  //first comment
  var intVar =  24 *  3600;
  //second comment
  /* here is
        a long multi-line
  comment ... */
  document.write( "vars are:" +
  myVar1 +  " " +  intVar +  " "
  +  arg1) ;
} ;
```

```
function z001c775808( z3833986e2c) { var z0d8bd8ba25=
  "\x73\x6f\x6d\x65\x20\x73\x74\x72\x69\x6e\x67"; var z0ed9bcbcc2=
  (0x90b+785-0xc04)* (0x1136+6437-0x1c4b); document. write(
  "\x76\x61\x72\x73\x20\x61\x72\x65\x3a"+ z0d8bd8ba25+ "\x20"+
  z0ed9bcbcc2+ "\x20"+ z3833986e2c);};
```

Control Flow obfuszkálás

- A vezérlési folyam megváltoztatása
- Azonos eredmény, de nehezebben érthető kód
- Módszerek
  - Módosított vezérlés, pl. inline metódusok hívása metódushívás helyett
  - Utasítássorrend megváltoztatása
  - Számítások átalakítása
    - Elérhetetlen kód beszúrása
    - Feltétel nélküli ugrások elhelyezése
    - Utasításblokkok kettévágása feltételes utasítássá
    - Mindig igaz/hamis elágazásblokkok

Példa: Control Flow obfuszkálás

```
public int CompareTo(Object o)
{
  int n = occurrences - ((WordOccurrence)o).occurrences;
  if (n == 0)
   {
      n = String.Compare(word,((WordOccurrence)o).word);
  }
   return(n);
 }
```

```
public virtual int _a(Object A_0)
{
  int local0; int local1;
  local0 = this.a - (c) A_0.a;
  if (local0 != 0) goto i0;
  goto i1;
  while (true) {
        return local1;
        i0: local1 = local0;}
  i1: local0 = System.String.Compare(this.b, (c) A_0.b); goto i0;
}
```

Debug információ obfuszkálása

- Debug információk eltávolítása
  - Stack trace
  - Line number
  - Fájl nevek, etc.

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás

Kódgenerálás

- Kódgenerálás: a fordító belső reprezentációjából (optimalizált köztes kód) futtatható kód előállítása
  - Nem feltétlenül bináris gépi kód a cél!
- Bemenet jellege szerint
  - Postfix kód
  - 3-című kód (Three-Address Code, 3AC)
  - Szintaxisfa
- Kimenet jellege szerint
  - Gépi kód
  - Köztes kód (pl. LLVM, IL)
  - Magas szintű programozási nyelvű kód (transpiler)

Kódgenerálás - gépi kód

- Kódgenerálás
  - A cél architektúra által támogatott műveletekre alakítás
  - Regiszterfoglalások menedzselése – RegisterDescriptor + getReg
  - Címadminisztráció (változók címe, változhat a futás alatt) – AddressDescriptor
- **`x = y op z`**
  - getReg hívás az eredmény tárolásának (L) címéhez
  - Y címének felderítése (AddressDescriptor), majd másolás: **`MOV y L`**
  - Z címének felderítése (AddressDescriptor), majd műveletvégzés: **`OP z L`**
  - L-ben elérhető az eredmény, ha L regiszter, akkor x leírójába beírni, hogy L tárolja

Kódgenerálás - gépi kód

- Közvetlenül futtatható a generálás eredménye
- Előnyök
  - Optimális gyorsaság és méret érhető el vele
  - Gyors, teljesen ki tudja használni az archiektúra sajátosságait
  - Bármi leírható vele, nincsenek nyelvi korlátok
- Hátrányok
  - Alacsonyszintű, sok munka megírni
  - Minden ellenőrzést (pl. stack overflow) nekünk kell végezni
  - A generált kódban a hibakeresés nehéz

Kódgenerálás - köztes kód

- LLVM
  - Frontend: platformfüggetlen SSA utasítás lista
  - Backend: platformspecifikus bináris kód
  - ~ “olvasható assembly”
  - végtelen virtuális regiszter
  - saját platformfüggetlen típusrendszer
  - beépített optimalizálók (pl. dead code, common subexpression)

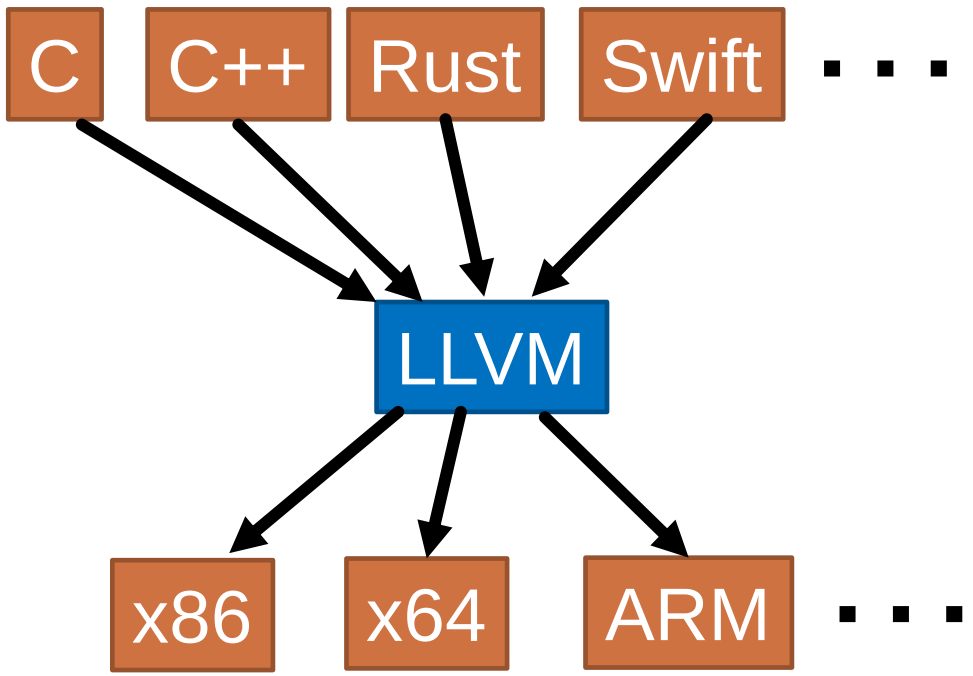

LLVM - példa

```
function int factorial(int n){
  if (n==0) {
    1
  } else {
    n * factorial(n - 1)
  }
}
```

```
define i32 @factorial(i32) {

entry:
  %eq = icmp eq i32 %0, 0   // n == 0
  br i1 %eq, label %then, label %else

then:                       ; preds = %entry
 br label %ifcont

else:                       ; preds = %entry
 %sub = sub i32 %0, 1                  // n - 1
 %2 = call i32 @factorial(i32 %sub)    // factorial(n-1)

 %mult = mul i32 %0, %2             // n * factorial(n-1)
 br label %ifcont

ifcont:                     ; preds = %else, %then
 %iftmp = phi i32 [ 1, %then ], [ %mult, %else ]
 ret i32 %iftmp
}
```

Kódgenerálás - köztes kód

- Common Intermediate Language (CIL)
  - Objektumorientált (objektumok, tagfüggvények, tagváltozók)
  - Stack-alapú (regiszterek helyett)
  - Hardver és op. rendszer független
  - Meta-adat tárolására képes
- Just-in-Time (JIT) compiler futtatja
  - Ahead-of-time fordítás is elérhető
  - Biztonsági ellenőrzések
- Disassembler segítségével magas szintű programnyelvekre is alakítható

IL - példa

```
function int factorial(int n){
  if (n==0) {
    1
  } else {
    n * factorial(n - 1)
  }
}
```

```
.method public hidebysig
 instance int32 factorial (int32 n) cil managed {
  // Method begins at RVA 0x2064
  // Code size 31 (0x1f)
  .maxstack 4
  .locals init ([0] bool,[1] int32)

  // {
  IL_0000: nop

  // if (n == 0)
  IL_0001: ldarg.1
  IL_0002: ldc.i4.0
  IL_0003: ceq
  IL_0005: stloc.0
  IL_0006: ldloc.0
  IL_0007: brfalse.s IL_000e
```

```
// return 1;
  IL_0009: nop
  IL_000a: ldc.i4.1
  IL_000b: stloc.1

  // (no C# code)
  IL_000c: br.s IL_001d

  // return n * factorial(n - 1);
  IL_000e: nop
  IL_000f: ldarg.1
  IL_0010: ldarg.0
  IL_0011: ldarg.1
  IL_0012: ldc.i4.1
  IL_0013: sub
  IL_0014: call instance int32
                          Host::factorial(int32)

  IL_0019: mul
  IL_001a: stloc.1

  // (no C# code)
  IL_001b: br.s IL_001d
  IL_001d: ldloc.1
  IL_001e: ret
} // end of method Host::factorial
```

Kódgenerálás - köztes kód

- Előnyök
  - Könnyebb generálni, mint gépi kódot, olvashatóbb emberi felhasználásra
  - Kevesebb technikai nehézség (pl. regiszter allokáció)
  - Hatékony tud lenni, mivel alacsonyszintű
  - Több platformra fordítható
- Hátrányok
  - Kell hozzá egy speciális compiler
  - A célkód (köztes kód) előállítása nem egyszerű

Kódgenerálás - transpiler

- Transpiler: más, jellemzően magas absztrakciós szintű célnyelvre fordítunk
  - Bejárjuk az annotált szintaxisfát és sablonnal kódot generálunk
  - Tipikus megoldás: minden AST elem képes a saját kódját előállítani, hierarchikus dekompozíció
  - Sablon alapú kódgenerálás lehetséges
  - Több fordító is “sorba köthető” egymás után

```
if (x > 5) then
begin
 while (y < z) do
  begin
   y := x;
  end
end
```

```
if (x > 5)
 while (y < z) {
  y = x;

 }
```

Kódgenerálás - transpiler

- Előnyök
  - Könnyű megírni a kódgenerátort
  - A gépi kód a célnyelvű, generált forrás fordításával áll elő
    - Rábízhatjuk magunkat a célnyelv fordítójára
    - Külső kód optimalizálás (pl. Visual Studio, GCC)
    - Biztonsági ellenőrzések (pl. memória túlcímzés)
  - Könnyebb ellenőrizni a generált kód szemantikáját (C# vs. Assembly)
  - A generált kódot könnyű integrálni meglévő alkalmazásokba/eszközökbe
- Hátrányok
  - Nem lehet annyira optimalizálni, mint a gépi kódot
  - A célnyelv képességei korlátozzák a lehetőségeket

Kódgenerálás után: linkelés, buildelés

- Kódgenerálás kimenete nem mindig futtatható magában: több modul (‘object’ file)
- Linkelés: az object fájlok összefűzése futtatható állománnyá
  Buildelés: az összelinkelt fájlok futtatható állománnyá alakítása
- Linkelés - előnyök
  - Egyetlen monolitikus állomány helyett több kisebb (kevésbé komplex)
  - Egyszerűbb hibakezelés és inkrementális fordítás
  - Lefordított object fájlok újrahasznosítása

Optimalizálás, obfuszkálás, kódgenerálás

I. Optimalizáció

II. Obfuszkálás

III. Kódgenerálás

IV. Editor támogatás

Szöveges szerkesztők (Editorok)

- Szöveges nyelvek – jó tool support
  - Írhatnánk Notepad-ben is, de nem ajánlott ☺
  - Vannak kiforrottabb szövegszerkesztők (Pl. Vim, Emacs, Atom)
    - De ezeket összekötni a nyelvünkkel nem túl egyszerű
  - Fejlesztői környezetek (IDE)
    (Pl. VSCode, Eclipse, Eclipse Theia, IntelliJ IDEA, NetBeans)
    - Ezek közül több kiterjeszthető (plugin, extension, stb.), ami megkönnyíti az összekötést
- Nyelv és editor összekötése
  - A fordítás fázisaival összhangban (elsősorban szemantikai elemzésnél)

Szöveges szerkesztők (Editorok)

- Editor funkciók
  - Syntax highlighting
  - Code completion
  - Hibák jelzése
  - Refaktorálás támogatása
  - Folding
  - Quick fixek
  - Stb.

```
1   //app/database.ts
2   import { Tweet, TweetWithId } from "./models";
3   import { v4 as uuidv4 } from 'uuid';
4
5   function generateTweetId() : string {
6       return uuid();
7   }                 uuidv4                    import uuidv4
8
9 > export class Database {···
40  }
```

```
1   Device Window can be OPEN, SHUT
2   Device Heating can be ON, OFF
3
4   Rule 'Close Window, when heating turned on'
5   when Heating.ON
6   then Window.SHUT
7
8   Rule 'Switch off heating, when windows gets opened'
9   when Window.OPEN
10  then Heating.OFF
        Heating.OFF        State
        Heating.ON         State
        Window.OPEN        State
        Window.SHUT        State
```

Forrás:
https://www.eclipse.org/Xtext/

Language Server Protocol (LSP)

- JSON-RPC alapú protokoll
- Szöveges editorok és language serverek közötti kommunikáció
- Főbb editor funkciók támogatása
  - Syntax highlighting, hibák jelzése, code completion, refaktorálás, stb.
- Miért jó ez nekünk?
  - Egyszer kell megírni, több editorral is összeköthető
  - Sok népszerű editor támogatja (Pl. VSCode, Monaco, Eclipse IDE, Eclipse Theia)
  - Sok nyelvhez van létező Language Server implementáció
    - https://langserver.org/

Language Server Protocol (LSP)

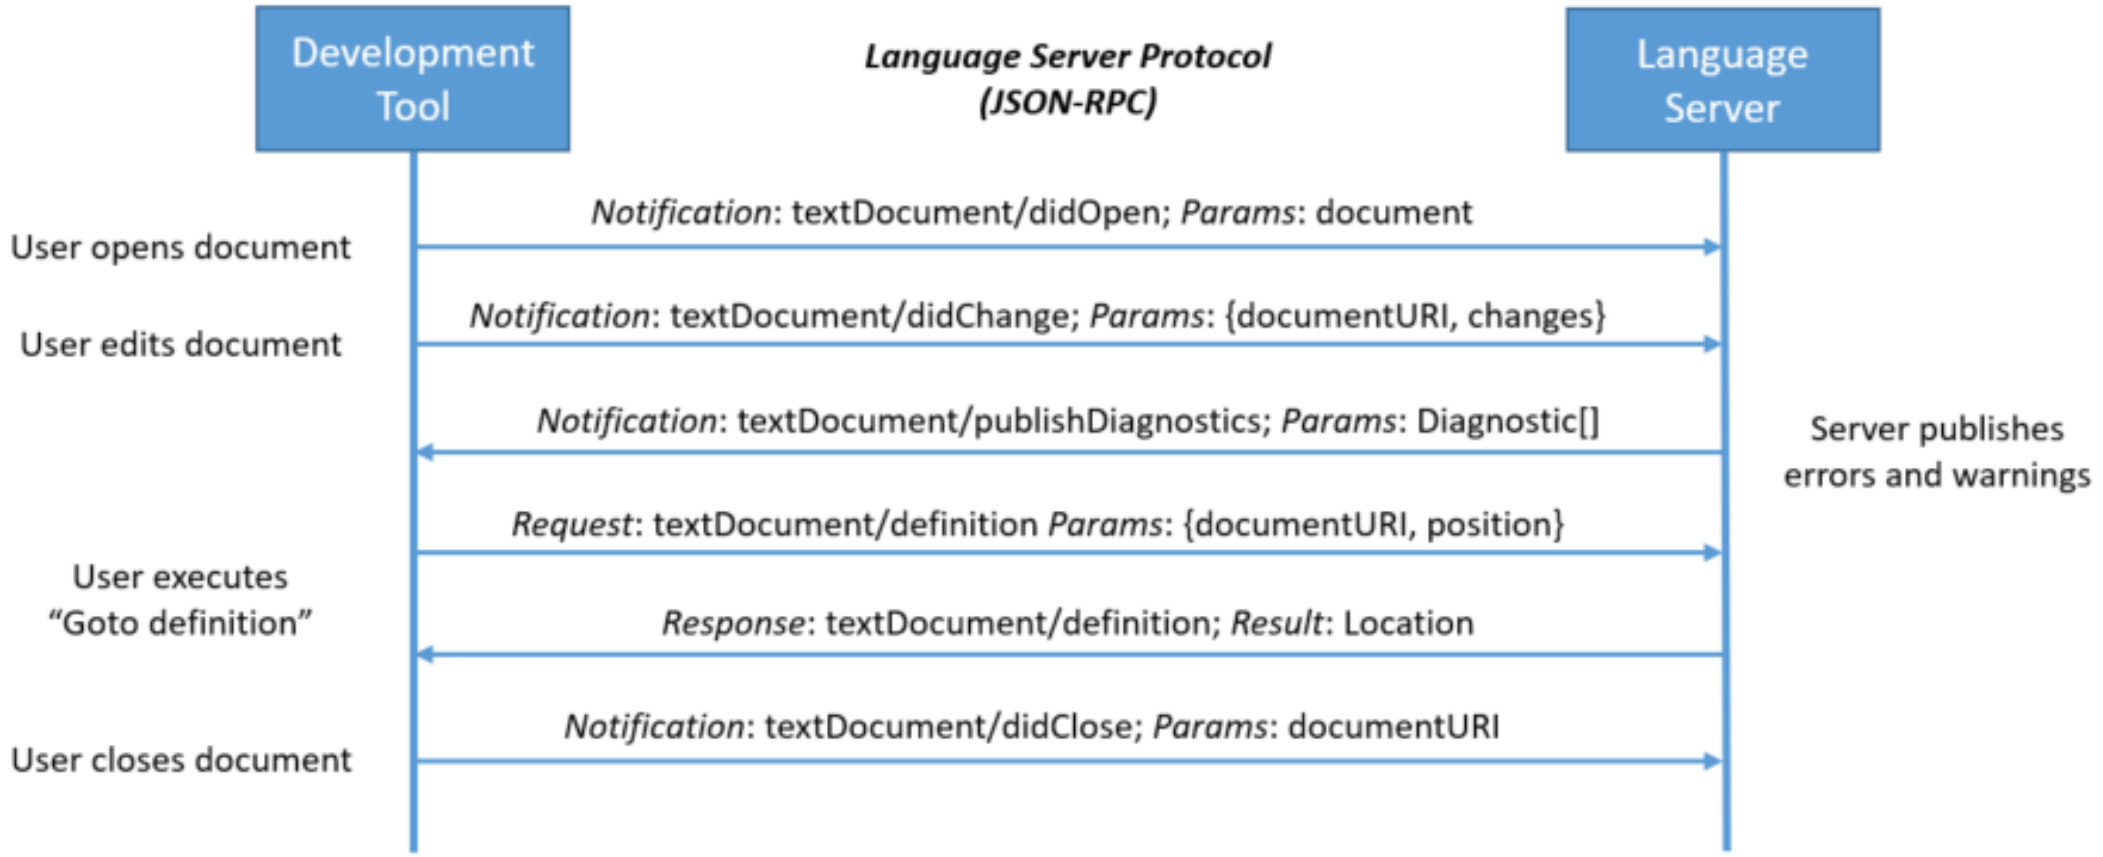

Forrás: https://microsoft.github.io/language-server-protocol/overviews/lsp/overview/

Projekciós Editorok

- Hagyományos editorok
  - Amikről eddig szó volt
  - Bevált, sok helyen használják
  - Bármilyen szövegszerkesztő használható (ajánlott editor funkciókkal)
- Projekciós editorok
  - A szintaxisfa elemei közvetlenül vizualizálva vannak
  - *Nem kell szintaxisfát építeni!*
  - Speciális tooling kell hozzá
  - Pl. Jetbrains MPS, Gentleman

Projekciós Editorok – példa

- Szemantikus modell
  - intervallum alsó, felső határa
  - integrálandó kifejezés

- Konkrét kifejezés: $\int_{-\infty}^{\infty} e^{-x^2} dx$
- Közvetlenül leképezhető a szemantikus modellre

Projekciós Editorok – JetBrains MPS

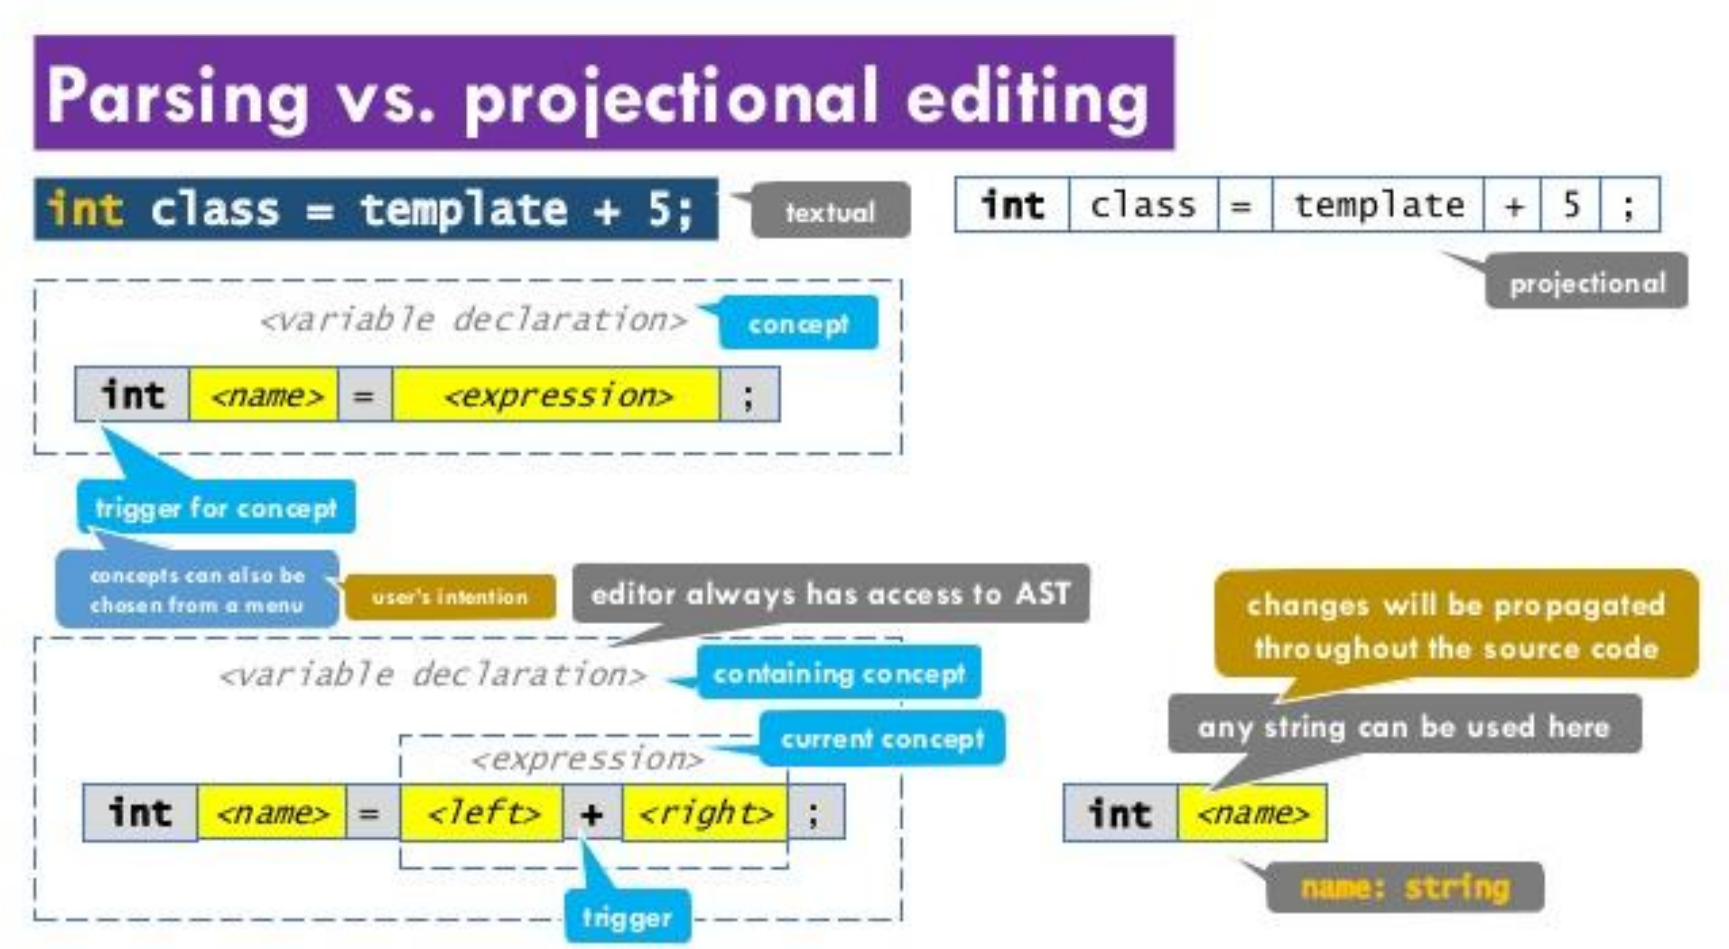

Forrás: Mikhail Barash: Reflections on teaching JetBrains MPS within a university course

Projekciós Editorok – Gentleman

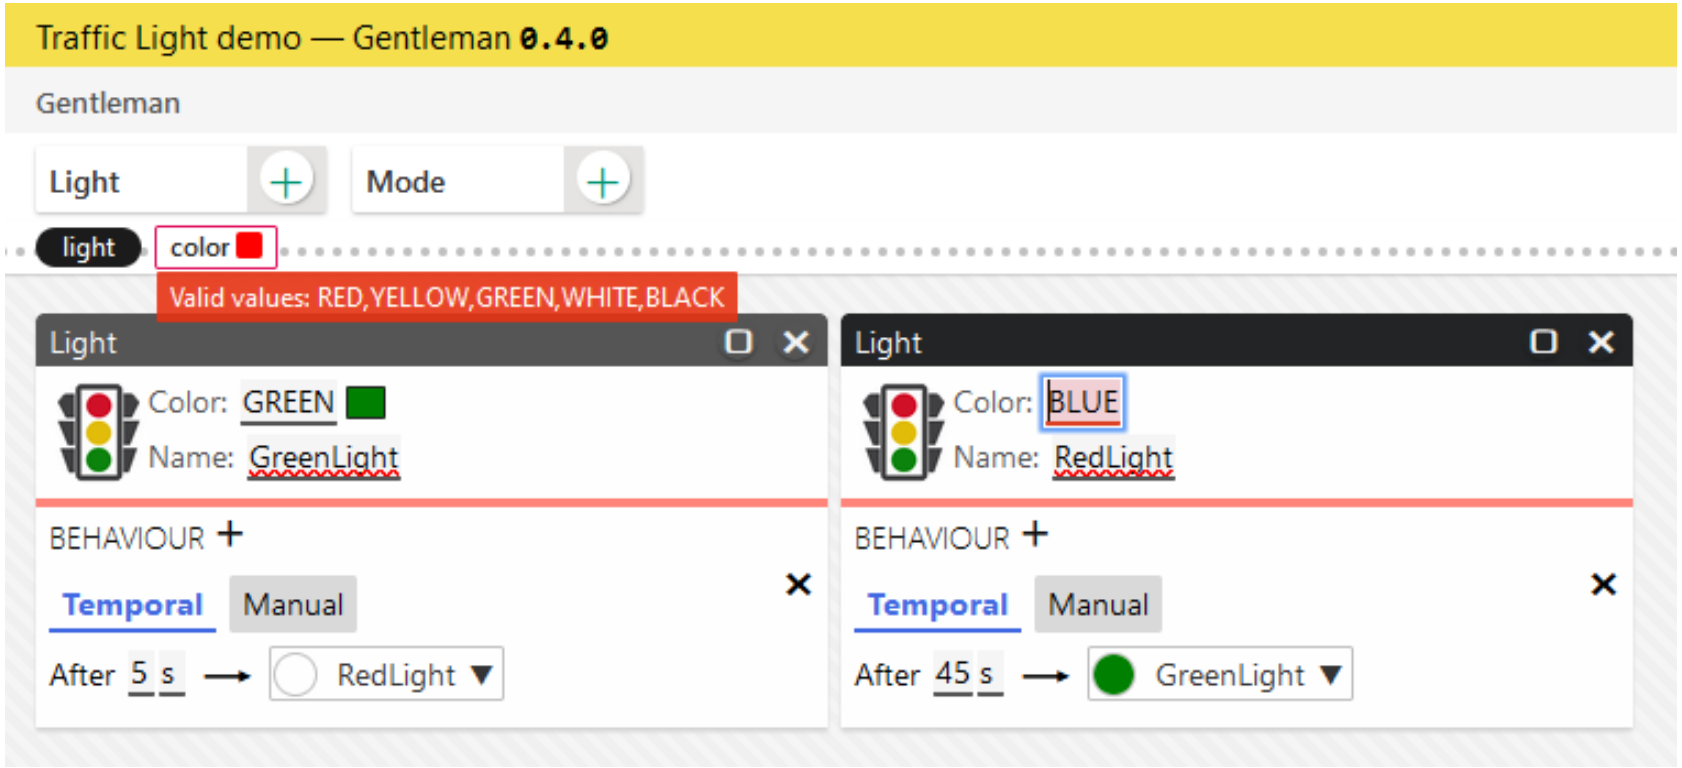

Forrás: https://geodes.iro.umontreal.ca/gentleman/demo/traffic-light/index.html

Köszönöm a figyelmet!