MODELLALAPÚ SZOFTVERFEJLESZTÉS – 4. GYAKORLAT – ANTLR

Szemantikai elemzés és kódgenerálás

Dr. Somogyi Ferenc

Budapesti Műszaki és Gazdaságtudományi Egyetem
Villamosmérnöki és Informatikai Kar
Automatizálási és Alkalmazott Informatikai Tanszék

1117 Budapest, Magyar tudósok körútja 2.
Q. ép. B. szárny 207. • www.aut.bme.hu
Telefon: 463-2870 • Fax: 463-2871

I. Bevezetés

A gyakorlat célja, hogy a 2. gyakorlaton elkészített prototípus programozási nyelv (TinyScript) nyelvtanából kiindulva elkészítsük a nyelv szemantikai elemzőjét, valamint egy kódgenerátort, amely TinyScript nyelven írt bemenetből Java kódot képes generálni. A szemantikai elemző kódja megtalálható a kiinduló projektben (jelen útmutatóban ezt nézzük végig), a **kódgenerátor** egy részét viszont **önállóan** kell majd megírni a **3. házi feladat** keretein belül. A gyakorlat során megismerkedünk a következőkkel:

- Visitor minta használata a szintaxis fa bejárása során
- Szemantikai elemzés: szimbólumtábla és típusellenőrzés megvalósítása
- Sablon alapú kódgenerátor készítése StringTemplate segítségével

Fontos: jelen útmutató az **ANTLR 4**-es verziójához készült. Az **ANTLR 3**-as verziója sok szempontból hasonló a 4-eshez, viszont még több szempontból nem. Az interneten fellelhető segédanyagoknál és kérdéseknél (pl. stackoverflow) érdemes meggyőződni róla, hogy melyik verzióról van szó.

StringTemplate beüzemelése IntelliJ környezetben

A StringTemplate[1] egy sablon alapú kódgeneráló eszköz. A kiinduló projektben az ANTLR-hez hasonlóan, megtalálható a *lib* mappa alatt egy jar fájl, ami a futáshoz szükséges. Az előző gyakorlaton látottakhoz hasonló módon, győződjünk meg róla, hogy a jar fájl ott van a projekt függőségei között (***File --> Project Structure... --> Modules --> Dependencies***), és ha nincs, adjuk hozzá. Ezen kívül telepítsük a megfelelő IntelliJ plugint is, szintén az ANTLR-hez hasonlóan. ***File --> Settings...*** menüpont, válasszuk oldalt a ***Plugins***-t, keressünk rá a StringTemplate-re, és telepítsük a plugint (utána indítsuk újra az IntelliJ-t):

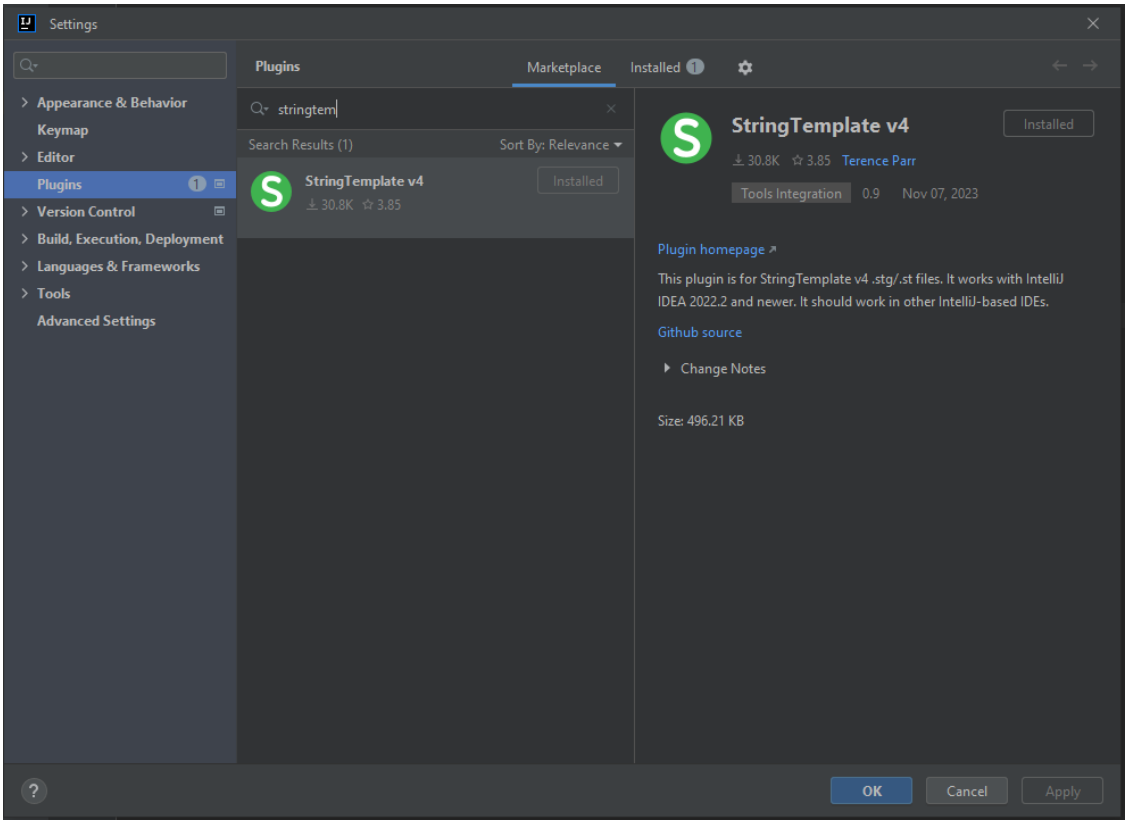

[1] https://www.stringtemplate.org/

II. SZEMANTIKAI ELEMZÉS

Töltsük le és nyissuk meg a kiinduló projektet! A következőkben a szemantikai elemzés folyamatát fogjuk röviden áttekinteni a kiinduló kód alapján; a teljes szemantikai elemző meg van írva.

SZIMBÓLUMTÁBLA

A TinyScript nyelvben változókat és függvényeket definiálhatunk, ezek lesznek a szimbólumaink. Mivel egy függvénynek több tulajdonsága van, mint egy változónak (lehetnek paraméterei), illetve máshogy is viselkednek (meg lehet őket hívni), külön kezeljük őket a scope-ban. A **tinyscript.symboltable** package alatt megtalálható a változó, függvény, és scope kezelése. A *FunctionSymbol* osztály *addParameter* függvényére azért van szükség, hogy duplikált paraméter nevek esetén testre szabhatóbb hibaüzenetet tudjunk adni. A *TSType* osztály a típusrendszer egy típusát írja le.

```
public class FunctionSymbol {
    public String name;
    public TSType returnType;
    public final HashMap<String, VariableSymbol> parameters = new HashMap<>();

    public FunctionSymbol(String name, TSType returnType) {
        this.name = name;
        this.returnType = returnType;
    }

    public boolean addParameter(String name, VariableSymbol paramSymbol) {
        if (parameters.containsKey(name)) {
            System.out.println("parameter '" + name + "' is already in scope");
            return true;
        }

        parameters.put(name, paramSymbol);
        return false;
    }

    @Override
    public String toString() { … }
} }
```

```
public class VariableSymbol {
    public TSType type;
    public String name;


    public VariableSymbol(TSType type, String name) {
        this.type = type;
        this.name = name;
    }

    @Override
    public String toString() { … }
}
```

A *Scope* osztály kezeli a parent scope-ot (*previous*), valamint támogatja a szokásos lookup és insert műveleteket (*getXY* és *addXY* függvények).

```
public class Scope {
    private final Scope previous;
    private final HashMap<String, VariableSymbol> variables = new HashMap<>();
    private final HashMap<String, FunctionSymbol> functions = new HashMap<>();

    public Scope getPrevious() {
        return previous;
    }

    public Scope(Scope previous) {
        this.previous = previous;
    }

    public VariableSymbol getVariable(String name) { … }

    public FunctionSymbol getFunction(String name) { … }

    public boolean addVariable(String name, VariableSymbol symbol) { … }

    public boolean addFunction(String name, FunctionSymbol symbol) { … }
    …
}
```

Típusrendszer

A típusrendszer felépítése a **tinyscript.typesystem** package alatt található. Egy típusnak szülőtípusai lehetnek, két típus kompatibilitását ezen reláció mentén tudjuk vizsgálni (*isCompatibleWith* függvény).

```
public class TSType {
    public String name;
    public HashSet<TSType> parents;

    public TSType(String name) {
        this.name = name;
        parents = new HashSet<>();
    }


    public boolean isCompatibleWith(TSType t) {
        return this == t || parents.stream().anyMatch(p -> p.isCompatibleWith(t));
    }
}
```

A *TypeSystem* osztályban található az összes beépített típus, itt adjuk meg a köztük lévő kapcsolatokat is. Az *ERROR* típusnak szülője lesz az összes egyéb beépített típus, a típushibák eszkalációjának elkerülése miatt. Saját típust is felvehetnénk (*createType* függvény), de a TinyScript nyelvben erre jelenleg nincs lehetőség. Ekkor kezelnünk kellene a *NULL* és *ERROR* típusok szülő kapcsolatait is, például egy új osztály mindkettőnek szülője kell legyen.

```
public class TypeSystem {
    private final HashMap<String, TSType> types;

    public TypeSystem() {
        types = new HashMap<>();
        initializeConstants();
    }
```

```
    public TSType BOOLEAN;
    public TSType INT;
    public TSType STRING;
    public TSType NULL;
    public TSType ERROR;
    public TSType VOID;

    private void initializeConstants() {
        this.ERROR = new TSType("ErrorType");
        this.STRING = new TSType("string");
        this.INT = new TSType("int");
        this.BOOLEAN = new TSType("bool");
        this.NULL = new TSType("NullType");
        this.VOID = new TSType("void");

        this.NULL.parents.add(this.STRING);
        this.ERROR.parents.add(this.INT);
        this.ERROR.parents.add(this.BOOLEAN);
        this.ERROR.parents.add(this.NULL);
        this.ERROR.parents.add(this.VOID);

        types.put(this.ERROR.name, this.ERROR);
        types.put(this.INT.name, this.INT);
        types.put(this.STRING.name, this.STRING);
        types.put(this.BOOLEAN.name, this.BOOLEAN);
        types.put(this.NULL.name, this.NULL);
        types.put(this.VOID.name, this.VOID);
    }

    public TSType getType(String name) {
        if (types.containsKey(name))
            return types.get(name);

        return this.ERROR;  // type error escalation
    }

    …
}
```

A *TypeSystemHelper* osztály a típusrendszer és szimbólumtábla (scope) alapján megmondja egy adott kifejezésről, hogy az milyen típusú. A típusrendszert és az aktuális scope-ot a visitor fogja átadni, utóbbi természetesen függ attól, hogy hol tartózkodunk a kódban. Bonyolultabb nyelvek esetén további segédosztályok és adatszerkezetek is készíthetők.

```
public class TypeSystemHelper {
    public static TSType getType(TinyScriptParser.ExpressionContext ctx, TypeSystem ts, Scope scope) {
        …
    }

    public static TSType getType(TinyScriptParser.PrimaryContext ctx, TypeSystem ts, Scope scope) {
        …
    }

    public static TSType getType(TinyScriptParser.FunctionCallContext ctx, TypeSystem ts, Scope scope) {
        …
    }

    public static TSType getType(TinyScriptParser.LiteralExpressionContext ctx, TypeSystem ts, Scope scope)
    {
```

```
        …
    }
}
```

Szintaxisfa bejárása visitor mintával

Az ANTLR nyelvtan minden parser szabályából egy saját Context osztály generálódik (pl. *IfStatementContext*), amely típusos API-t biztosít arra, hogy lekérjük a fában a gyerekeit. A visitor minta alapgondolata, hogy szétválasztja az adatszerkezet bejárását attól, hogy az egyes csomópontokban mit kell tennünk. Az ANTLR alapértelmezetten mélységi bejárást (DFS) alkalmaz, amit részben vagy egészben felüldefiniálhatunk a *return* utasítások átszervezésével a *visit* függvényeken belül, de előfordulhat, hogy erre nincs szükség.

A **tinyscript** package *TinyScriptSemanticAnalyzer* osztálya felelős a teljes szemantikai elemzés elvégzéséért. Kezelünk egy *scope*-ot (melyet majd dinamikusan változtatunk) és egy típusrendszert (*ts*). Az *exceptionHandler* a hibaüzenetek kezeléséért felelős. A *currentFunction* tagváltozóra azért van szükség, hogy a függvények paramétereinél és a return utasításnál tudjuk, hogy melyik függvényhez köthető az adott hiba, hol vagyunk éppen.

```
public class TinyScriptSemanticAnalyzer extends TinyScriptBaseVisitor<Object> {
    private Scope scope;
    private TypeSystem ts;
    private final TinyScriptExceptionHandler exceptionHandler;
    private FunctionSymbol currentFunction = null;

    public TinyScriptSemanticAnalyzer(TinyScriptExceptionHandler exceptionHandler) {
        this.exceptionHandler = exceptionHandler;

        scope = new Scope(null);
        ts = new TypeSystem();
    }
…
```

A továbbiakban nem fogjuk teljesen végig nézni a szemantikai elemzőt, csak néhány fontosabb részletet emelünk ki. Függvény definíció bejárásánál (*FunctionDefinitionContext*) először betesszük a függvényt az aktuális scope-ba és egy új, lokális scope-ot nyitunk a függvénynek, hiszen lehetnek lokális tagváltozók, amiket csak a függvény belsejéből érhetünk el. Ezután a függvény utasításainak bejárása következik (a *super.visitFunctionDefinition*-t kiemeltük, nem térünk vele vissza azonnal), utána pedig visszaállítjuk a scope-ot. Figyeljük meg, hogy a *FunctionDefinitionContext* osztályon azokat a függvényeket tudjuk elérni, amely parser szabályokat a nyelvtanban definiáltunk!

```
    @Override
    public Object visitFunctionDefinition(TinyScriptParser.FunctionDefinitionContext ctx) {
        var name = ctx.functionName().getText();
        var returnType = ts.getType(ctx.returnType().getText());
        currentFunction = new FunctionSymbol(name, returnType);
        addFunctionToScope(ctx, currentFunction);

        scope = new Scope(scope);
        System.out.println("Function entry");

        var result = super.visitFunctionDefinition(ctx);

        System.out.println("Function exit");
        System.out.println(scope.toString());
        scope = scope.getPrevious();
```

```
        currentFunction = null;

        return result;
    }
```

Return utasítás esetén meg kell néznünk, hogy függvényen belül vagyunk-e, erre is jó a korábban említett *currentFunction* tagváltozó. Ezen kívül a visszatérés típusát is tudjuk ellenőrizni.

```
    @Override
    public Object visitReturnStatement(TinyScriptParser.ReturnStatementContext ctx) {
        if (currentFunction == null) {
            addException(ctx, "return statements can only be present inside a function");
        }
        else {
            var type = TypeSystemHelper.getType(ctx.expression(), ts, scope);
            if (!type.isCompatibleWith(currentFunction.returnType))
                addException(ctx, "return statement type " + type.name + " is not compatible with function
return type " + currentFunction.returnType.name);
        }

        return super.visitReturnStatement(ctx);
    }
```

Változó deklaráció során több feladatunk is van: „var” kulcsszó használata esetén ellenőriznünk kell, hogy legyen kezdeti érték; ha van kezdeti érték (de nincs „var” kulcsszó), akkor pedig a változó típusával kompatibilisnek kell lennie a kezdeti értéket leíró kifejezésnek. Ezen kívül a változót be kell szúrnunk az aktuális scope-ba.

```
    @Override
    public Object visitVariableDeclaration(TinyScriptParser.VariableDeclarationContext ctx) {
        var varName = ctx.varName().getText();
        // var
        if (ctx.VAR() != null) {
            if (ctx.expression() == null)
                addException(ctx, "variables declared using 'var' must have an initial value");
            else {
                var type = TypeSystemHelper.getType(ctx.expression(), ts, scope);
                var symbol = new VariableSymbol(type, varName);
                addVariableToScope(ctx.varName(), symbol);
            }
        }
        // not var
        else {
            var type = ts.getType(ctx.typeName().getText());

            if (ctx.expression() == null) {
                var symbol = new VariableSymbol(type, varName);
                addVariableToScope(ctx.varName(), symbol);
            }
            else {
                var expressionType = TypeSystemHelper.getType(ctx.expression(), ts, scope);
                if (!expressionType.isCompatibleWith(type))
                    addException(ctx, "an expression of type '" + expressionType.name + "' is not
assignable" + " to variable '" + varName + "' of type " + type.name);
                else {
                    var symbol = new VariableSymbol(type, ctx.varName().getText());
                    addVariableToScope(ctx.varName(), symbol);
                }
```

```
            }
        }
        System.out.println("Var declaration visited");
        System.out.println(scope.toString());
        return super.visitVariableDeclaration(ctx);
    }
```

A visitor konzolra kiírja a főbb lépéseket, illetve a talált hibákat is. Érdemes lefuttatnunk (*TinyScriptRunner* osztály) és végig követnünk, hogy pontosan hogyan működik, valamint az *input.tys* fájl átírásával tesztelnünk az elemzőt.

A szemantikai elemzés során, amikor szimbólumtáblát (vagy hasonló adatszerkezetet) kell felépítenünk, általában több visitort készítünk. Az első visitor felépíti a szimbólumtáblát és a felépítés közben jelzi az esetleges hibákat (pl. ha két globális függvénynek ugyanaz a neve), majd a felépített szimbólumtábla alapján a második (vagy akár az N-edik, több is lehet) visitor elvégzi a szemantikai elemzés azon ellenőrzéseit, amelyekhez a teljes szimbólumtáblára szükség van (pl. hogy létezik-e az adott függvény). A kiadott kódban mi ezt megspóroltuk, a fa bejárási sorrendjének megváltoztatásával (ld. visitProgram függvény) először a függvények kerülnek beszúrásra a scope-ba. Ha feltesszük, hogy függvényen belül nem tudunk más függvényt hívni, akkor ez egy jó megoldás, ellenkező esetben szükségünk lenne egy másik visitorra, ami az előzőek alapján felépíti a szimbólumtáblát.

III. KÓDGENERÁLÁS

A TinyScript nyelv esetén a transzformáció és optimalizáció kimarad, a szemantikai elemzés után a kódgenerálás következik. A kódgenerálást is a visitor minta alapján végezzük. Egy sablon alapú transpilert fogunk készíteni, ami a TinyScript nyelven leírt kódot Java kóddá alakítja át, a StringTemplate[2] technológia felhasználásával. Mindig pontosan egy Java osztályt generálunk (pl. *TinyScriptOutput*) egy main függvénnyel; a TinyScript nyelven leírt további függvények is ebbe az osztályba fognak generálódni. A generált fájl alapértelmezetten a **tinyscript.generated** package-ben jön létre.

Mivel a TinyScript és a Java nyelv között nagyon nagy a szintaktikai hasonlóság, ezért egyszerű dolgunk lesz a kódgenerálás során. Az utasításokat szinte teljesen át tudjuk venni, néhány kivételtől eltekintve (típusnevek) mindkét nyelvben ugyanaz az utasítások szintaxisa. A kódgenerálás egy része megtalálható a kiinduló projektben, ezt tekintjük át a következőkben. A kódgenerálás további feladatai a házi feladat részét képezik.

FONTOS: ha hibás fájlt generálnánk, az IntelliJ IDEA (mivel Java projekt van megnyitva) nem engedheti futtatni az alkalmazást. Ekkor töröljük ki a generált fájlt és futtassuk újra a TinyScriptRunner osztály main függvényét.

Kezdjük a StringTemplate használatával: a **tinyscript.codegen.stringtemplate** package alatt található egy úgynevezett group file (*JavaGen.stg*), ami tetszőleges számú sablont (template) tartalmaz. A tényleges kód (visitor) megírása során a sablonokat paraméterekkel látjuk el (pl. packageName, functions, stb.), valamint tartalmukat más sablonba is beágyazhatjuk. Sablonon belül paramétert a < > karakterek használatával tudunk behelyettesíteni. A *java* sablon a generált kód vázát tartalmazza: egy package és osztálydefiníciót, az osztályon belül függvényeket, valamint egy main függvényt. A **függvények generálása** nincs megoldva, ez a **házi feladat része**. A *statements* sablon nagyon egyszerű, az utasításokat (vagyis tetszőleges stringeket) gyűjti egymás után, újsor karakterrel elválasztva. Ehelyett használhatnánk StringBuilder-t is a kódban, de a StringTemplate egyik előnye, hogy nincs szükség manuális string összefűzésekre, helyettük inkább felparaméterezett sablonokat használunk.

[2] https://github.com/antlr/stringtemplate4/blob/master/doc/index.md

```
java(packageName, className, functions, mainBody) ::= <<
package <packageName>;

public class <className> {
    <functions; separator="\n">

    public static void main(String[] args) {
        <mainBody>
    }
}
>>

statements(statement) ::= <<
<statement; separator="\n">
>>
```

A **tinyscript.codegen** package *TinyScriptCodeGenerator* osztálya – hasonlóan a szemantikai elemzőhöz – egy visitor, ami a kódgenerálást végzi. Ehhez szükség van a StringTemplate *groupFile*-ra, az ebben található fő sablonra (*javaTemplate*), valamint egy külön tagváltozót készítettünk a main függvényen belül található utasításoknak is (*mainStatementsTemplate*), ami a fent említett *statements* sablont használja. A *visit* függvény felüldefiniálásával megadjuk a generálás menetét: példányosítjuk a *statements* sablont, bejárjuk a szintaxisfát, a végén pedig az összegyűjtött utasításokat hozzáadjuk a fő (*java*) sablonhoz, mint paraméter (*mainBody*). Végül a generált kód a *java* sablon által renderelt szöveg lesz.

```
public class TinyScriptCodeGenerator extends TinyScriptBaseVisitor<Object> {
    public String generatedCode = "";
    private final STGroupFile groupFile;
    private final ST javaTemplate;
    private ST mainStatementsTemplate;

    public TinyScriptCodeGenerator(String stGroupPath, String javaTemplate, String packageName, String
className) {
        this.groupFile = new STGroupFile(stGroupPath);
        this.javaTemplate = groupFile.getInstanceOf(javaTemplate);
        this.javaTemplate.add("packageName", packageName);
        this.javaTemplate.add("className", className);
    }

    @Override
    public Object visit(ParseTree tree) {
        mainStatementsTemplate = groupFile.getInstanceOf("statements");

        var result = super.visit(tree);
        javaTemplate.add("mainBody", mainStatementsTemplate);
        generatedCode = javaTemplate.render();
        return result;
    }
…
```

A szintaxisfa bejárása során minden utasításból készítünk egy stringet (*processStatement*), mely során a két nem Java kompatibilis típusnevet (string és bool) lecseréljük. Egy komplexebb nyelvnél (illetve ahol a célnyelv szintaxisa nem lenne ennyire hasonló) ez persze sokkal bonyolultabb feladat lenne, itt ezt a lépést leegyszerűsítjük. Az *if* és *while* utasításokra külön figyelnünk kell, hogy ne járjuk be őket még egyszer, különben duplikálnánk a generált kódot, mivel ezen utasítások belseje is *statement*-eket tartalmaz. A *getFullSourceText* segédfüggvény arra szolgál, hogy a szintaxisfába nem bekerülő whitespace és újsor karakterek is megjelenjenek a generált kódban.

```
@Override
    public Object visitStatement(TinyScriptParser.StatementContext ctx) {
        mainStatementsTemplate.add("statement", processStatement(ctx));

        if (ctx.ifStatement() == null && ctx.whileStatement() == null)
            return super.visitStatement(ctx);
        else return null;
    }

    private String processStatement(TinyScriptParser.StatementContext ctx) {
        return getFullSourceText(ctx).replace("string", "String").replace("bool", "boolean");
    }

    private String getFullSourceText(ParserRuleContext context) {
        CharStream cs = context.start.getTokenSource().getInputStream();
        int stopIndex = context.stop != null ? context.stop.getStopIndex() : -1;
        return cs.getText(new Interval(context.start.getStartIndex(), stopIndex));
    }
```

A kódgenerálás során is használhatnánk a szimbólumtáblát vagy típusrendszert, ez bonyolultabb nyelvek esetén gyakori. A mostani feladatnál például a típusnevek konvertálását TinyScript és Java nyelv között (string --> String és bool --> boolean) szebben is meg tudnánk csinálni, ha használnánk és kiegészítenénk a TypeSystem osztályt, de itt az egyszerűség mellett döntöttünk.

A kódgenerálás a *TinyScriptRunner* osztályban van felparaméterezve (input és output fájlok, StringTemplate sablon) és a *main* függvényt futtatva, a szemantikai elemzés után fut le. A kiinduló projektben található **kódgenerátor hibás**, a függvények utasításait is a main függvényen belülre generálja (pl. *return a +b;*), ezt a **házi feladat** során kell majd megoldanunk! A kiinduló projektben található példa bemenetre (*input.tys*) található egy példa kimenet is (*TinyScriptOutputExample.java*).