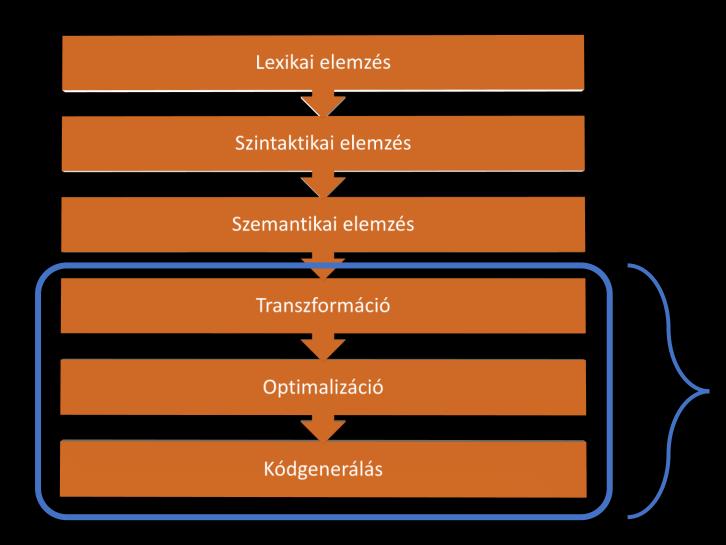
LLVM

Gembela Gergely

Mi is az LLVM?

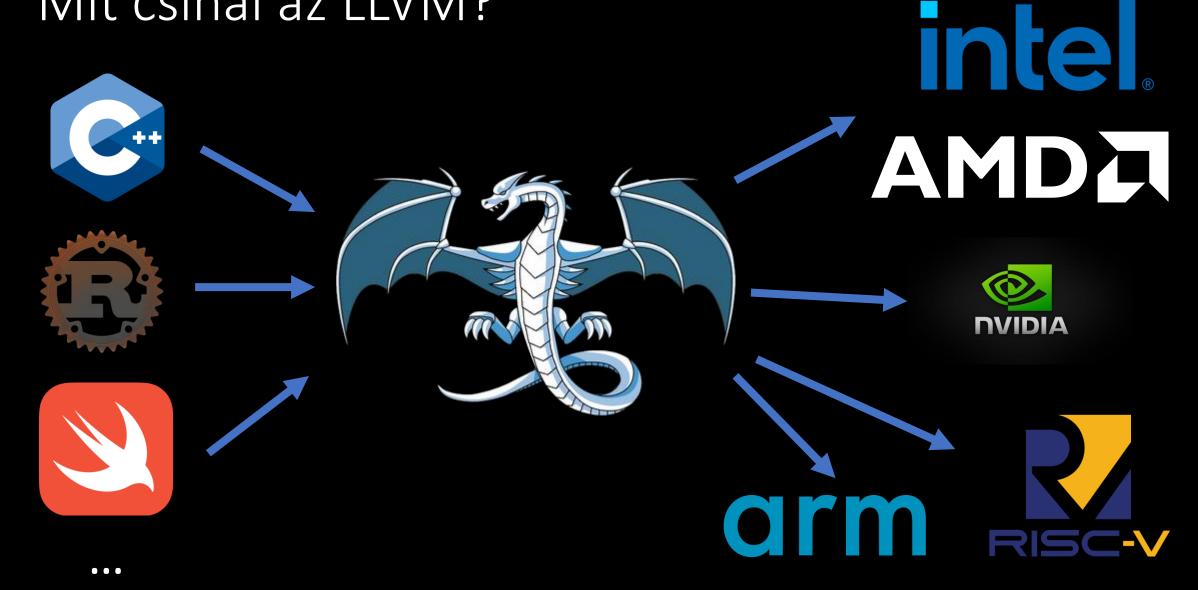
- Fordítók készítéséhez és teszteléséhez használható eszközök gyűjteménye (és már NEM a Low-Level Virtual Machine mozaikszava)
- Több népszerű nyelvhez van LLVM alapú fordító, vannak nyelvek amik kifejezetten LLVM alapú fordítóikkal együtt fejlődnek
 - Rust
 - Zig
 - Nim
 - Clang C++, Objective C, C
 - Swift

Az LLVM feladatai egy fordítóban



Middle-end és backend: Az LLVM eszközei első sorban a fordítás ezen szakaszára adnak megoldást

Mit csinál az LLVM?



A sárkányon belül

- IR nyelv
 - Frontendfüggetlen*
 - Platformfüggetlen*
- Optimalizáció
 - Kiterjeszthető, személyre szabható lépések
 - Az IR nyelven elérhetők
- Platformspecifikus backendek
- Linker
 - Képes link-time optimalizációkra



Egy modern LLVM alapú fordító

Lexer+Parser

AST



Egy modern LLVM alapú fordító

Lexer+Parser

AST

Semantic analysis

A

High-level IR

Language specific optimiaztions

Transformations

LLVM IR Generation

Egy modern LLVM alapú fordító

Lexer+Parser

AST

Semantic analysis



High-level IR

Language specific optimiaztions

Transformations

LLVM IR Generation

Optimizations

Target-specific backend

Link-time optimizations (IId)



LLVM IR

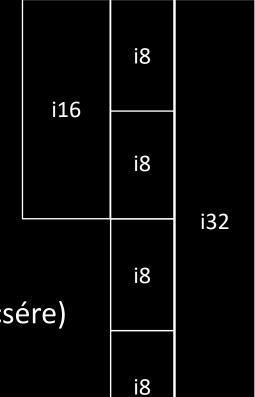
- A legtöbb modern fordítóban van megfelelője
 - GCC RTL
 - .A NET IL + Roslyn hasonló, de más célok
 - Kifejezetten .NET a CLR számára készült
 - Objektumorientált, típusos nyelv
 - A .NET IL tároló is, biztosítja a bináris kompatibilitást
 - LLVM IR-t jellemzően nem terjesztenek a toolchainek (de link-time optimization miatt még ez is előfordulhat)
 - A .NET IL stabil, és tényleg platformfüggetlen
 - Java bytecode
 - SPIR-V (shaderek esetén)

LLVM IR

- 3 alak bitcode, in-memory IR, szöveges
- Az LLVM IR típusos
 - Régebben még a pointerek is, ez mostanra eltűnőben van (szerencsére)
- Definiálhatók saját típusok
 - Ezek leginkább a C struktúrákhoz hasonlítanak, DE alignment!
- 2 féle ID
 - @global globális
 - %local lokális
- A kódot modulokba szervezi

LLVM IR

- 3 formában használjuk bitcode, in-memory IR, szöveges
- Az LLVM IR típusos %struct.vec4 = type { i16, i16, i16, i16 }
 - Régebben még a pointerek is, ez mostanra eltűnőben van (szerencsére)
- Definiálhatók saját típusok
 - Ezek leginkább a C struktúrákhoz hasonlítanak, DE alignment!
- 2 féle ID minden elemhez (változó, függvény, modul)
 - @global globális
 - %local lokális
- A kódot modulokba szervezi (egy fordítási egység, pl. egy .cpp file)
 - Jelenleg csak modulon belüli optimalizációkkal foglalkozunk



@square - C++

```
int square(int num) {
    return num * num;
} //C/C++
```

```
define i32 @square(int)(i32 noundef
%0) {
    %2 = mul nsw i32 %0, %0
    ret i32 %2
} ;LLVM IR
```

@square - rs

```
pub fn square(num: i32) -> i32 {
    num * num
} //RS
```

```
define i32 @square(int)(i32 noundef
%0) {
    %2 = mul nsw i32 %0, %0
    ret i32 %2
} ;LLVM IR
```

@square – Swift

```
func square(n: Int) -> Int {
    return n * n
} //Swift
```

```
define i32 @square(int)(i32 noundef
%0) {
    %2 = mul nsw i32 %0, %0
    ret i32 %2
} ;LLVM IR
```

@square – Ilc (debug/release/ssa/...)

```
define dso_local noundef i32
@square(int)(i32 noundef %0) #0 !dbg !10 {
    %2 = alloca i32, align 4
    store i32 %0, ptr %2, align 4
    tail call void @llvm.dbg.declare(metadata
ptr %2, metadata !16, metadata
!DIExpression()), !dbg !17
    %3 = load i32, ptr %2, align 4, !dbg !18
    %4 = load i32, ptr %2, align 4, !dbg !19
    %5 = mul nsw i32 %3, %4, !dbg !20
    ret i32 %5, !dbg !21
}
```

```
define i32 @square(int)(i32 noundef
%0) {
    %2 = mul nsw i32 %0, %0
    ret i32 %2
} ;LLVM IR
```

@square – a kimenet

```
square(int): # WASM
                                                                       local.get
square:
                                                                       local.get
      # x86-64
                                                                       i32.mul
                 eax, edi
        mov
                                                                       end_function
        imul
                 eax, eax
        ret
                              define i32 @square(int)(i32 noundef %0)
                                %2 = \text{mul nsw i32 } \%0, \%0
                                ret i32 %2
                              } ;LLVM IR
                                                                         square: # RISC-V
            //arm64
  square:
                                                                         mul
                                                                                  a0, a0, a0
          w0, w0, w0
  mul
                                                                         ret
  ret
```

@érdekesség – nvcc

```
.visible .entry square(int*, int)(
       .param .u64 square(int*, int)_param_0,
       .param .u32 square(int*, int)_param_1
       ld.param.u64
                      %rd1, [square(int*, int)_param_0];
       ld.param.u32
                      %r1, [square(int*, int)_param_1];
       cvta.to.global.u64 %rd2, %rd1;
       mul.lo.s32 %r2, %r1, %r1;
                      [%rd2], %r2;
       st.global.u32
       ret;
```

LLVM Pass (IR->IR)

- Kód2kód transzformáció
- Akár mi is írhatunk
- De van néhány ami már meg van írva, és nyelvfüggetlenül elérhető
 - Érdekesség: ennyire egyszerű egy saját pass-t készíteni

```
#include "llvm/IR/PassManager.h"

namespace llvm {

class HelloWorldPass : public PassInfoMixin<HelloWorldPass> {
 public:
    PreservedAnalyses run(Function &F, FunctionAnalysisManager &AM);
};

} // namespace llvm
```

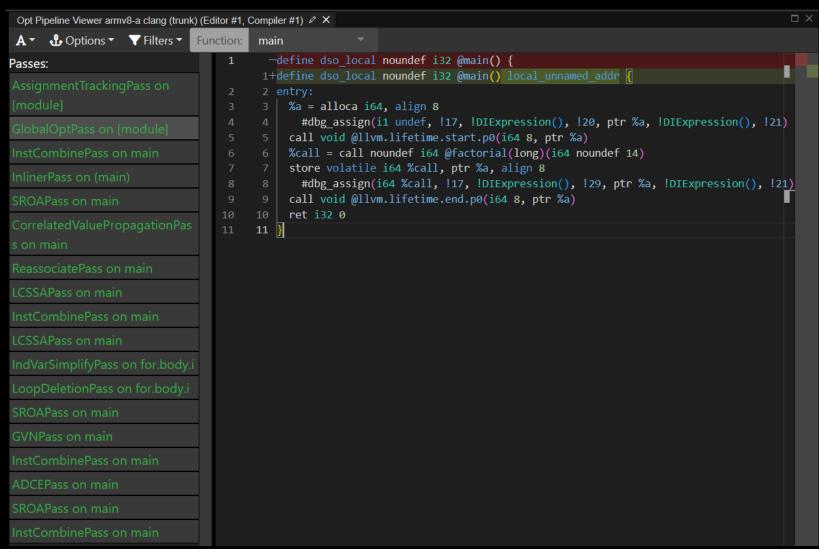
Optimalizálás LLVM segítségével

- Az összes tanult optimalizáló algoritmus elérhető, és akár saját implementáció is készíthető rájuk
- Sok pass nem része az alapértelmezetten engedélyezett szinteknek (Itt a szintek Pl. O[0-3], Ofast, Os, Oz)
- Nem minden optimalizáció platformfüggetlen!
 - Pl. SIMD instrukciók generálása (SSE/AVX, Arm Neon,)
- Egy később futó pass visszavonhatja egy előtte futó transzformációját
- A passek külön is tesztelhetők az opt eszközzel, pl.
 - opt -passes='loop-unroll'
 - opt -passes='dce'

Az optimalizáló pipeline megtekintése

```
C++ source #1 / X
                                                                  armv8-a clang (trunk) (Editor #1) / X
                                        C++
                                                                                                          -O2 -emit-llvm
                                                                  armv8-a clang (trunk)
      #include <stdio.h>
                                                                                               ef i32 @main() local unnamed addr #0 !dbg
      inline long factorial(long n){
                                                                         Clone Compiler
          long res = 1;
                                                                                               gn 8
                                                                         Optimization
          for(long i = 2; i <= n; i++){
                                                                                               .dbg.assign(metadata i1 undef, metadata !
              res *= i;
                                                                         Stack Usage
                                                                                               time.start.p0(i64 8, ptr nonnull %a), !db
                                                                                               7178291200, ptr %a, align 8, !dbg !23
          return res;
                                                                         # Preprocessor
                                                                                               .dbg.assign(metadata i64 poison, metadata
                                                                         AST
                                                                                               time.end.p0(i64 8, ptr nonnull %a), !dbg
      int main() {
                                                                         ± LLVM IR
12
          volatile auto a = factorial(14);
                                                                         Opt Pipeline
                                                                                               etime.start.p0(i64 immarg, ptr nocapture)
                                                                        Device
                                                                         Control Flow Graph
                                                                                               etime.end.p0(i64 immarg, ptr nocapture) #
                                                                         declare void @llvm.dbg.assign(metadata, metadata, metadata, met
                                                                         attributes #0 = { mustprogress nofree norecurse nounwind memory
                                                                         attributes #1 = { mustprogress nocallback nofree nosync nounwin
                                                                         attributes #2 = { nocallback nofree nosync nounwind speculatable
                                                                         !20 = distinct !DIAssignID()
                                                                         !28 = distinct !DIAssignID()
```

Az optimalizáló pipeline megtekintése



Példa: dead code elimination

```
long dce(long n){
   long res = 1;
   auto c = res - 3;
   return res;
}
```

Példa: Mem2Reg (valójában SROA+Mem2Reg)

```
long sroa(long n){
    long res = 1;
    return res + n;
}
```

Példa: loop átalakítása (InvVarSimplify, deletion)

```
int whatever42(int a){
    int x = 3;
    for(int i = 0; i < a; i++){
        int c = a*a;
        x += c;
    }
    return x;
}</pre>
```

Példa: constant inlining

```
inline long factorial(long n){
   long res = 1;
   for(long i = 2; i <= n; i++){
      res *= i;
   }
   return res;
}

int main() {
   volatile auto a = factorial(14);
}</pre>
```

Példa: loop unroll

```
void vecadd(float a[4], float b[4]){
    for(int i = 0; i < 4; i++){
        a[i] = b[i];
    }
}</pre>
```

Extrém példa: dead code elimination #2

```
fn square(num: i32) -> i32 {
    num * num
} //RS
```

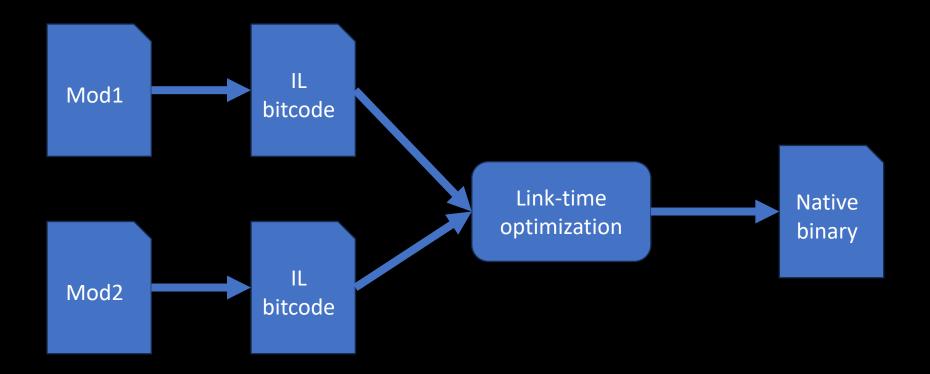
Extrém példa: dead code elimination #2

```
fn square(num: i32) -> i32 {
    num * num
}
;igen, ez egy üres textbox :D
```

Mivel a függvény nem publikus és nincsen felhasználva, a fordító egyszerűen megszabadul tőle...

Link-time optimalizáció

- A modulok szintjénél magasabb szintű, a teljes programot fedő optimalizáció
- Fordításidő szempontjából jelentős többletet jelenthet, nehezen párhuzamosítható



Ki használja?









SONY







Stats



Jun 3, 2001 – Mar 26, 2024

Contributions to main, line counts have been omitted because commit count exceeds 10,000.



Köszönöm a figyelmet!

Források, hasznos anyagok

The Architecture of Open Source Applications (Volume 1)LLVM (aosabook.org)

LLVM IR and Go | Gopher Academy Blog

Using the New Pass Manager — LLVM 19.0.0git documentation

Compiling With Clang Optimization Flags — Incredibuild

LLVM IR:

LLVM Assembly Language Reference Manual (apple.com)

Videók:

LLVM in 100 Seconds (youtube.com)

(5) 2023 EuroLLVM - Tutorial: A whirlwind tour of the LLVM optimizer — YouTube